Dimensionality Reduction

Machine Learning

Curse of Dimensionality

- Số chiều cao khiến khoảng cách giữa các điểm dữ liệu trở nên đồng nhất, gây khó khăn cho các thuật toán học máy trong việc tìm các mẫu (patterns).
- Tăng khả năng overfitting do có quá nhiều feature không cần thiết.
- Số lượng chiều lớn làm **tăng** yêu cầu về bộ nhớ và thời gian tính toán.

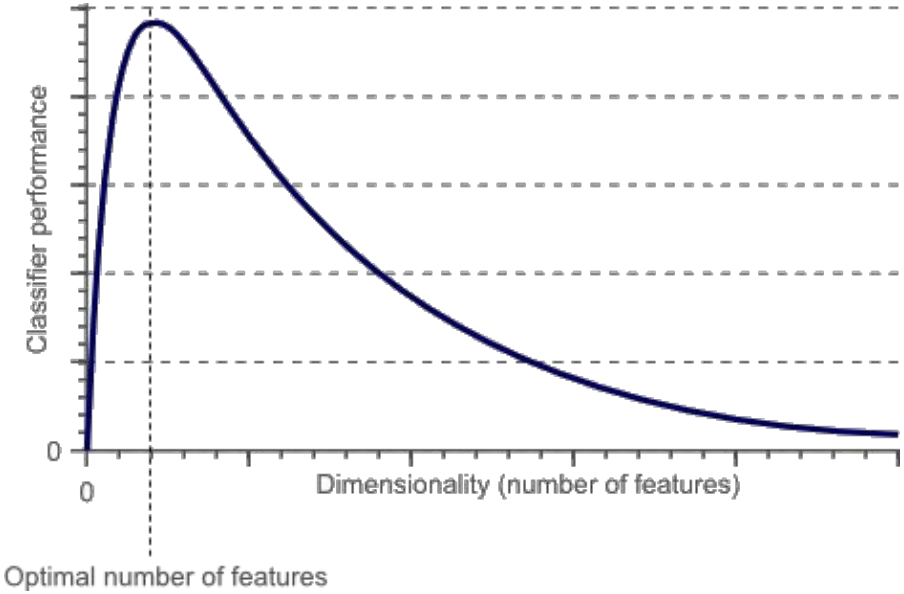

What is Dimensionality Reduction?

- **Giảm chiều dữ liệu** là một quá trình trong học máy và phân tích dữ liệu nhằm giảm số lượng biến đầu vào hoặc đặc trưng trong một tập dữ liệu, trong khi vẫn giữ lại các thông tin quan trọng và liên quan nhất.
- **Key Objectives:**
  - Simplify Data
  - Enhance Visualization
  - Improve Model Performance

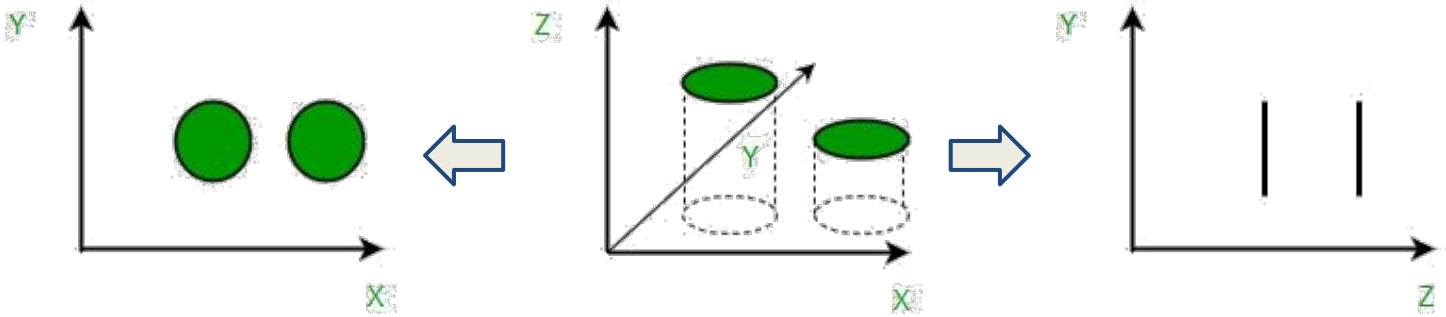

Common Approaches

- **Feature Selection**: Giữ lại các đặc trưng quan trọng nhất dựa trên các tiêu chí thống kê hoặc thuật toán.
- **Feature Extraction**: Tạo ra các tập hợp đặc trưng nhỏ hơn, mới thông qua các phép biến đổi.
- **Manifold Learning**: Ánh xạ dữ liệu trong không gian nhiều chiều sang manifold có số chiều thấp hơn, bảo toàn các mối quan hệ và cấu trúc
- **Autoencoders**: Sử dụng mạng neuron để mã hóa dữ liệu thành một biểu diễn nén.

Applications

- **Image processing**
- **Natural language processing (NLP)**
- **Genomics**
- **Recommender systems**

Feature Selection

Lựa chọn đặc trưng là một kỹ thuật trong giảm chiều dữ liệu nhằm xác định và giữ lại *các đặc trưng quan trọng nhất* trong tập dữ liệu.

- *Phương pháp phổ biến:*
  - Filter Methods
  - Wrapper Methods
  - Embedded Methods

Filter Methods

Feature Selection

Filter Methods

Phương pháp lọc *đánh giá tầm quan trọng của các đặc trưng* dựa trên các *thuộc tính thống kê của dữ liệu.* Các phương pháp này độc lập với các thuật toán học máy.

- *Các kỹ thuật chính:*
  - Hệ số tương quan Pearson.
  - Mutual Information.

Pearson Correlation Coefficient

Đo lường mối quan hệ tuyến tính giữa hai biến. Các đặc trưng có tương quan cao với biến mục tiêu nhưng ít tương quan với nhau sẽ được chọn.

- *Công thức:*

$$r = \frac{\mathrm{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

- *Trong đó:*

$$\mathrm{Cov}(X, Y) = \frac{\sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y})}{n}$$

$$\sigma_X = \sqrt{\frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{n}}$$

Ví dụ - Pearson Correlation Coefficient

Giả sử chúng ta có tập dữ liệu sau:

X	Y
2	4
4	6
6	8

Hãy tính hệ số tương quan Pearson giữa 2 biến X, Y.

Ví dụ - Pearson Correlation Coefficient - Solution

1. **Tính trung bình**:

$$\bar{X} = \frac{2+4+6}{3} = 4$$

$$\bar{Y} = \frac{4+6+8}{3} = 6$$

2. **Tính (Xi-Xbar), (Yi-Ybar):**

Xi	Yi	Xi−Xbar	Yi−Ybar
2	4	-2	-2
4	6	0	0
6	8	2	2

3. **Tính Cov(X, Y):**

$$\mathrm{Cov}(X,Y) = \frac{(-2)(-2)+(0)(0)+(2)(2)}{3} = \frac{8}{3} \approx 2.67$$

4. **Tính độ lệch chuẩn:**

$$\sigma_X = \sqrt{\frac{(-2)^2+(0)^2+(2)^2}{3}} = \sqrt{\frac{8}{3}} \approx 1.63$$

$$\sigma_Y = \sqrt{\frac{(-2)^2+(0)^2+(2)^2}{3}} = \sqrt{\frac{8}{3}} \approx 1.63$$

5. **Tính hệ số tương quan Pearson:**

$$r = \frac{\mathrm{Cov}(X,Y)}{\sigma_X \sigma_Y} = \frac{2.67}{1.63 * 1.63} = 1$$

Ví dụ - Dự đoán giá nhà

Giả sử chúng ta có tập dữ liệu sau:

	Price	Size	Bedrooms	Distance_to_City	Age
0	200000	1200	3	10	20
1	300000	1500	4	5	15
2	250000	1300	3	8	25
3	400000	2000	5	2	10
4	350000	1700	4	4	5

Hãy lựa chọn những đặc trưng tốt nhất để xây dựng mô hình dự đoán giá nhà.

Mutual Information (MI)

Đo lường lượng thông tin mà một biến cung cấp về biến khác. Không giống như tương quan Pearson, MI có thể nắm bắt cả quan hệ tuyến tính và phi tuyến.

- Công thức (trường hợp rời rạc):

$$MI(X,Y) = \sum_{x \in X} \sum_{y \in Y} P(x,y) \log \left(\frac{P(x,y)}{P(x)P(y)} \right)$$

Ví dụ - Dự đoán bệnh tim

Giả sử chúng ta có tập dữ liệu sau:

Age	Cholesterol	Blood_Pressure	Smoking	Heart_Disease
45	200	130	1	1
54	180	140	0	0
65	220	150	1	1
50	190	135	0	0
70	250	160	1	1

Hãy lựa chọn những đặc trưng tốt nhất để xây dựng mô hình dự đoán bệnh tim.

Ví dụ - Dự đoán bệnh tim - Solutions

- Kết quả tính toán hai hệ số MI và Pearson như sau:

Feature	MI score	Pearson CC
Age	0.673012	0.420277
Cholesterol	0.673012	0.756644
Blood_Pressure	0.673012	0.416954
Smoking	0.673012	1.00

Wrapper Methods

Feature Selection

Wrapper Methods

Phương pháp bọc chọn đặc trưng bằng cách lặp lại việc *đánh giá các tập con của đặc trưng* sử dụng một *mô hình dự đoán*.

- *Các kỹ thuật chính:*
  - Recursive Feature Elimination (RFE)
  - Forward/Backward Selection

Recursive Feature Elimination (RFE)

Huấn luyện một mô hình và loại bỏ dần các đặc trưng ít quan trọng nhất dựa trên điểm số tầm quan trọng của đặc trưng.

Các bước thực hiện:

Bước 0: Bắt đầu với tất cả các đặc trưng: F={1,2,…,p}.

Bước 1: Huấn luyện mô hình f(X,y,W) trên toàn bộ tập đặc trưng F.

Bước 2: Tính độ quan trọng L của đặc trưng dựa trên W (*Vd:* $L_i = |\mathbf{w_i}|$, $i \in F$)

Bước 3: Loại bỏ đặc trưng ít quan trọng nhất $F = F \setminus \{i^*\}$, $i^* = \text{argmin } L_i$, $i \in F$

Bước 4: Lặp lại Bước 1 cho đến khi |F| = k, k là số đặc trưng mong muốn

Ví dụ - RFE với Linear Regression trên Diabetes dataset

	AGE	SEX	BMI	BP	··· Serum Measurements ···						Response
Patient	x1	x2	x3	x4	x5	x6	x7	x8	x9	x10	y
1	59	2	32.1	101	157	93.2	38	4	4.9	87	151
2	48	1	21.6	87	183	103.2	70	3	3.9	69	75
3	72	2	30.5	93	156	93.6	41	4	4.7	85	141
4	24	1	25.3	84	198	131.4	40	5	4.9	89	206
5	50	1	23.0	101	192	125.4	52	4	4.3	80	135
6	23	1	22.6	89	139	64.8	61	2	4.2	68	97
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
441	36	1	30.0	95	201	125.2	42	5	5.1	85	220
442	36	1	19.6	71	250	133.2	97	3	4.6	92	57

age	sex	bmi	bp	s1	s2	s3	s4	s5	s6
6	2	1	1	1	1	4	3	1	5

Forward Selection

Quy trình:

1. **Bắt đầu** với mô hình rỗng (không có đặc trưng nào).
2. **Thêm đặc trưng** vào mô hình theo cách tăng dần:
    - Tại mỗi bước, chọn đặc trưng không nằm trong mô hình hiện tại và có đóng góp lớn nhất (theo một tiêu chí như R2 score, AIC, BIC, hoặc độ chính xác).
3. **Dừng lại** khi việc thêm bất kỳ đặc trưng nào không cải thiện hiệu suất của mô hình hoặc đạt được số lượng đặc trưng mong muốn.

Backward Selection

Quy trình:

1. **Bắt đầu** với tất cả các đặc trưng trong mô hình.
2. **Loại bỏ đặc trưng** một cách giảm dần:
    - Tại mỗi bước, loại bỏ đặc trưng ít đóng góp nhất (dựa trên tiêu chí tương tự như trên).
3. **Dừng lại** khi việc loại bỏ thêm bất kỳ đặc trưng nào làm giảm hiệu suất của mô hình hoặc đạt được số lượng đặc trưng mong muốn.

Embedded Methods

Feature Selection

Embedded Methods

Phương pháp nhúng kết hợp lợi thế của phương pháp lọc và bọc bằng cách *tích hợp việc chọn đặc trưng vào quá trình huấn luyện thuật toán học máy*.

- *Các kỹ thuật chính:*
  - Lasso Regression (Regularization L1)
  - Ridge Regression (Regularization L2)

Lasso Regression

Các Bước Chính trong Lasso Regression để Lựa chọn Đặc trưng

1. **Loss Function với thành phần Regularization**:

$$J(w) = \frac{1}{2n} \sum_{i=1}^{n} \left(y_i - \sum_{j=1}^{p} w_j x_{ij} \right)^2 + \lambda \sum_{j=1}^{p} |w_j|$$

   - λ: Tham số điều chỉnh độ mạnh của phạt (penalty).
   - λ lớn: Tăng cường phạt, nhiều hệ số được đưa về 0, loại bỏ nhiều đặc trưng hơn.
2. **Chọn lọc đặc trưng**:
   - Nếu w_j=0, đặc trưng j bị loại bỏ.

Ví dụ - Lasso Regression

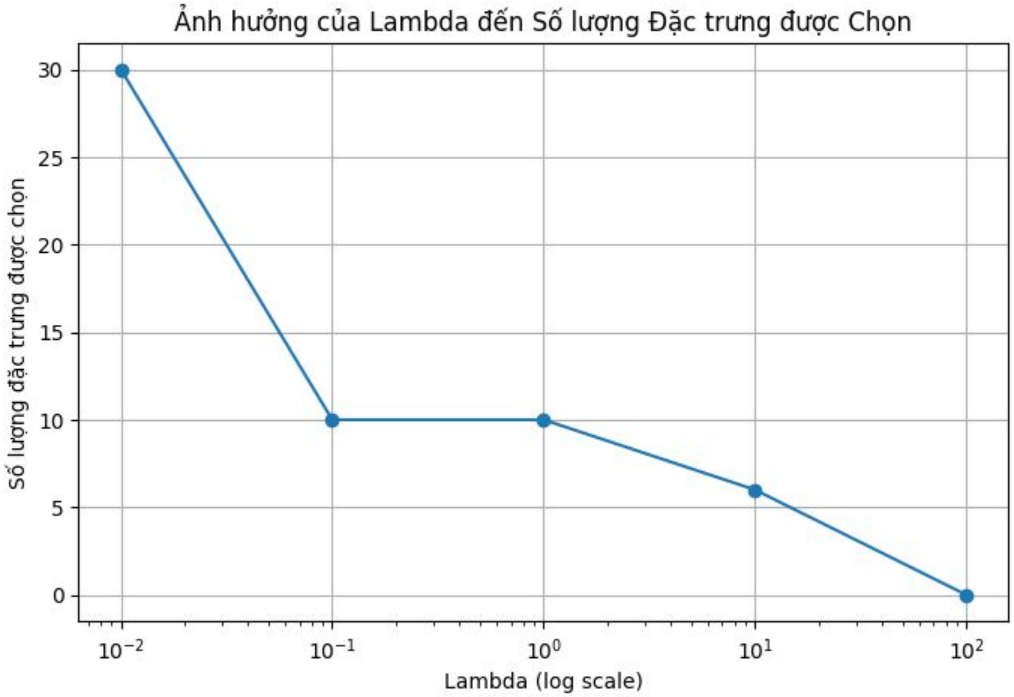

Ridge Regression

Thêm một thuật ngữ phạt tỷ lệ với bình phương của các hệ số, làm giảm độ lớn của các hệ số nhưng không làm chúng bằng 0.

- *Hàm mục tiêu:*

$$J(w) = \frac{1}{2n} \sum_{i=1}^{n} \left(y_i - \sum_{j=1}^{p} w_j x_{ij} \right)^2 + \lambda \sum_{j=1}^{p} {w_j}^2$$

- *Ý nghĩa:*
  - Xử lý overfitting
  - Giảm ảnh hưởng của **multicollinearity**

Vấn đề multicollinearity

Multicollinearity là một vấn đề thường gặp trong hồi quy bội (Multiple Regression), và nó cũng có thể xảy ra trong **Polynomial Regression**.

Khi có multicollinearity, các biến độc lập trong mô hình có sự tương quan mạnh với nhau, dẫn đến nhiều hệ quả tiêu cực trong việc ước lượng các hệ số hồi quy và làm giảm độ tin cậy của mô hình.

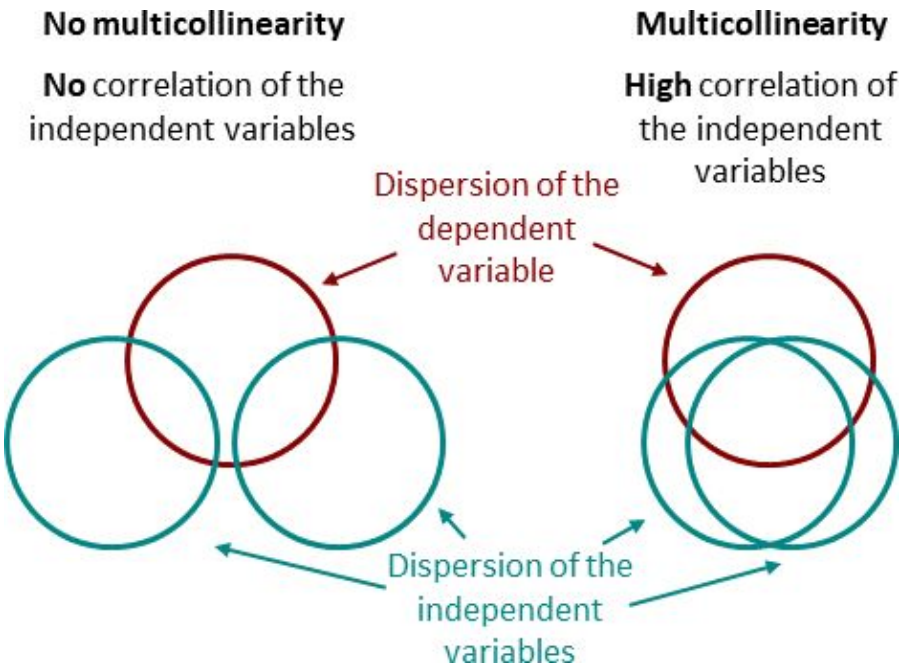

Ví dụ - Ridge Regression

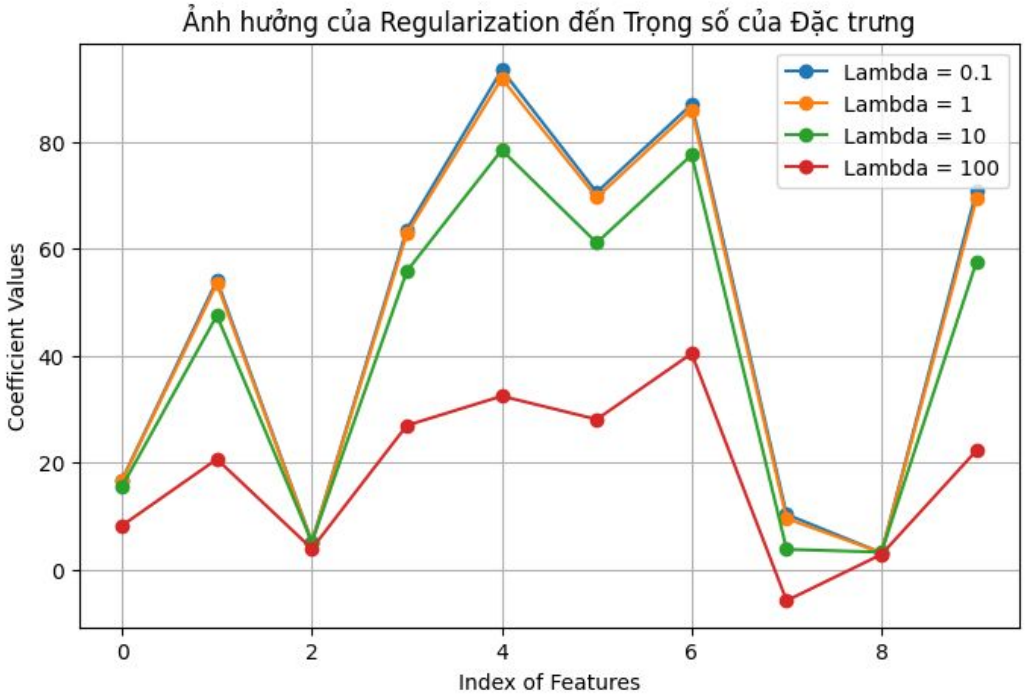

Comparison of Methods

Method	Advantages	Disadvantages
Filter Methods	Fast, independent of models	Ignores feature interactions
Wrapper Methods	High accuracy, considers interactions	Computationally expensive
Embedded Methods	Efficient, integrated with models	Performance depends on the algorithm

References

[1] https://cloud.google.com/discover/what-is-unsupervised-learning?hl=en

[2] https://machinelearningmastery.com/dimensionality-reduction-for-machine-learning/

[3] https://www.geeksforgeeks.org/dimensionality-reduction/

[4] https://blog.dataiku.com/dimensionality-reduction-how-it-works-in-plain-english

[5] https://developers.google.com/machine-learning/crash-course/embeddings/embedding-space