Dimensionality Reduction

Machine Learning

Matrix Factorization

Khái niệm: Biến đổi dữ liệu gốc thành các thành phần mới (features) để giảm chiều.

Các phương pháp phổ biến:

- Principal Component Analysis
- Singular Value Decomposition
- Non-Negative Matrix Factorization

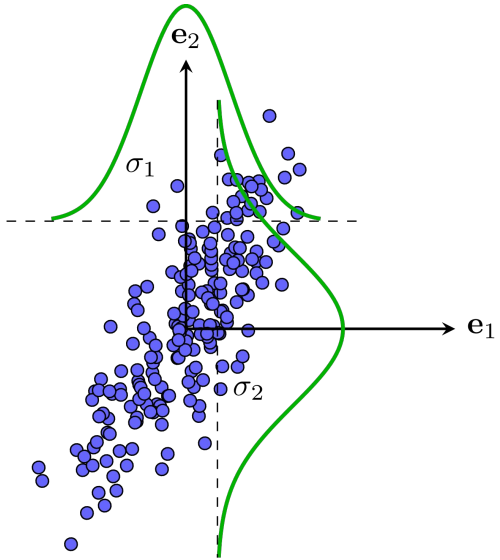

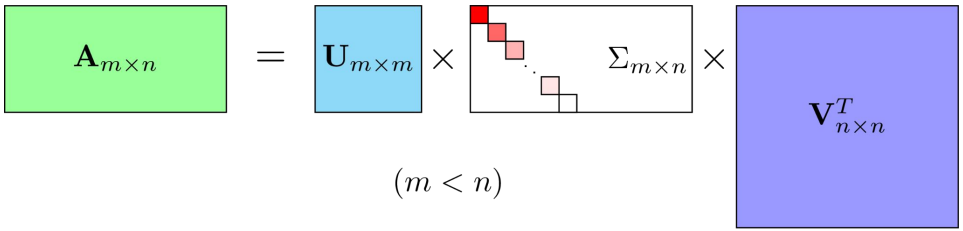

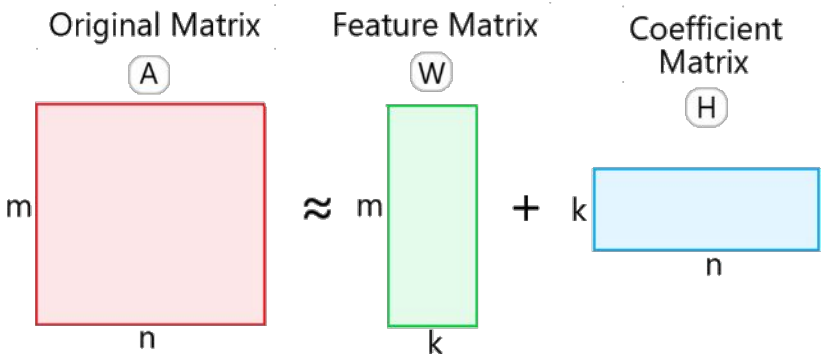

Principal Component Analysis

Matrix Factorization

Ý tưởng

- Loại bỏ thành phần mà các điểm dữ liệu sai khác nhau không đáng kể (**phương sai** nhỏ)

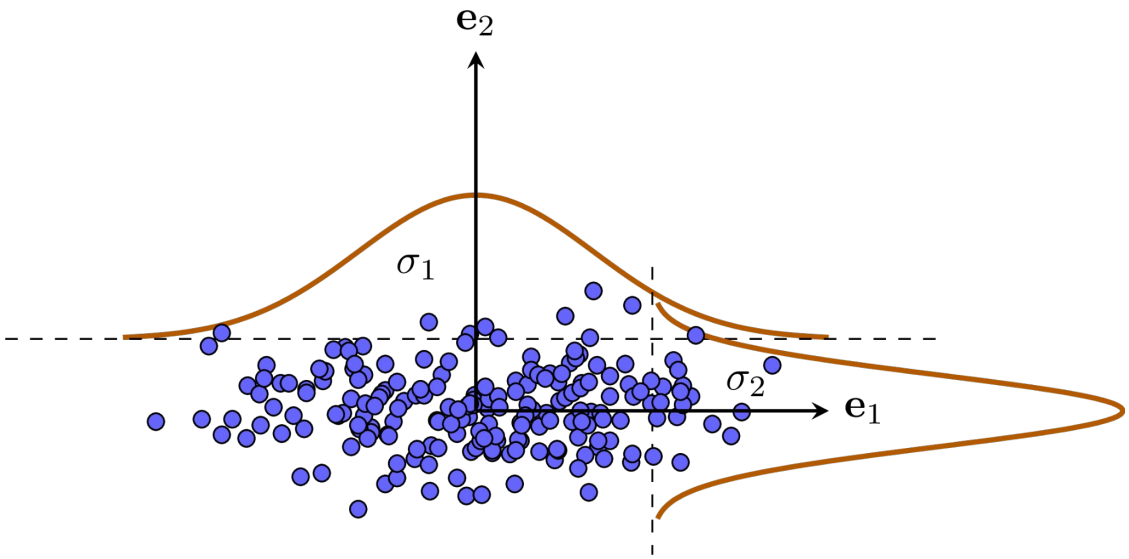

Ý tưởng

- Xoay dữ liệu một góc phù hợp khi **phương sai** của các chiều là đáng kể.

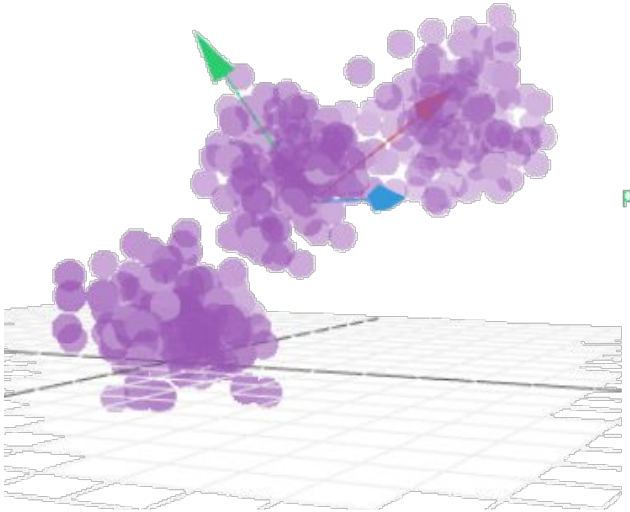

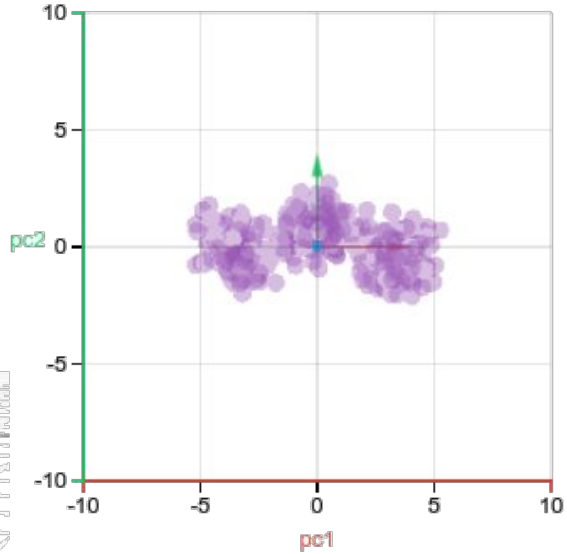

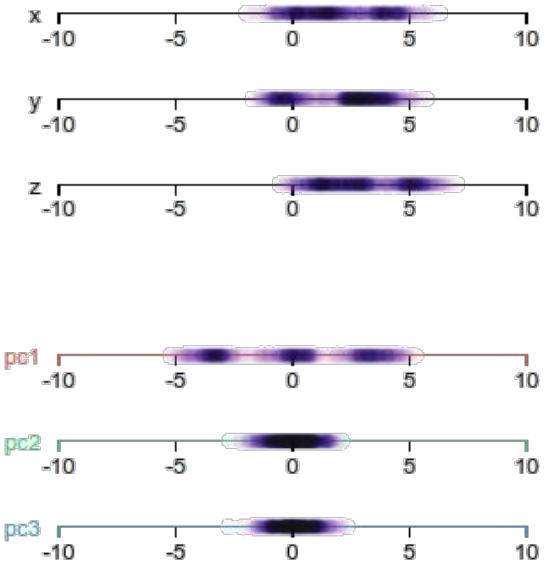

https://setosa.io/ev/principal-component-analysis/

Các bước thực hiện

1. Find mean vector

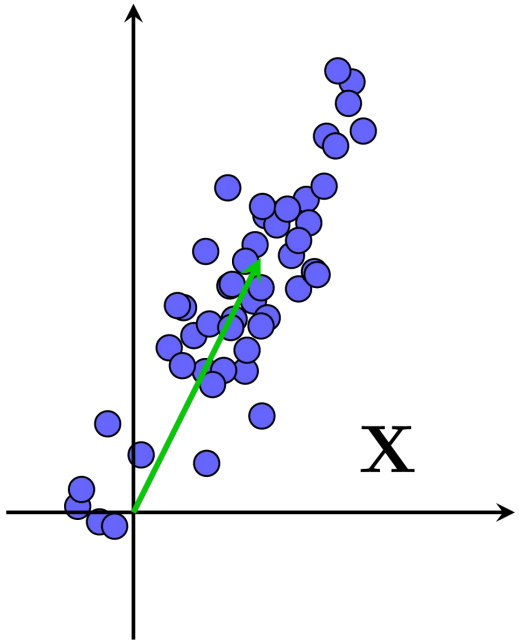

2. Subtract mean

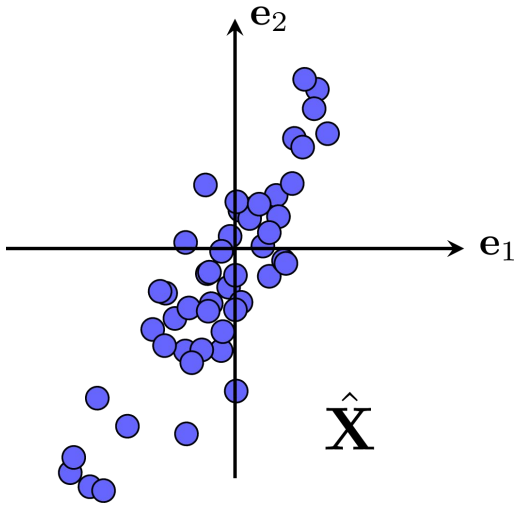

3. Compute covariance matrix:
$\mathbf{S} = \frac{1}{N}\hat{\mathbf{X}}\hat{\mathbf{X}}^T$

4. Computer eigenvalues and eigenvectors of $\mathbf{S}$:
$(\lambda_1, \mathbf{u}_1), \ldots, (\lambda_D, \mathbf{u}_D)$
Remember the orthonormality of $\mathbf{u}_i$.

Các bước thực hiện

5. Pick K eigenvectors w. highest eigenvalues

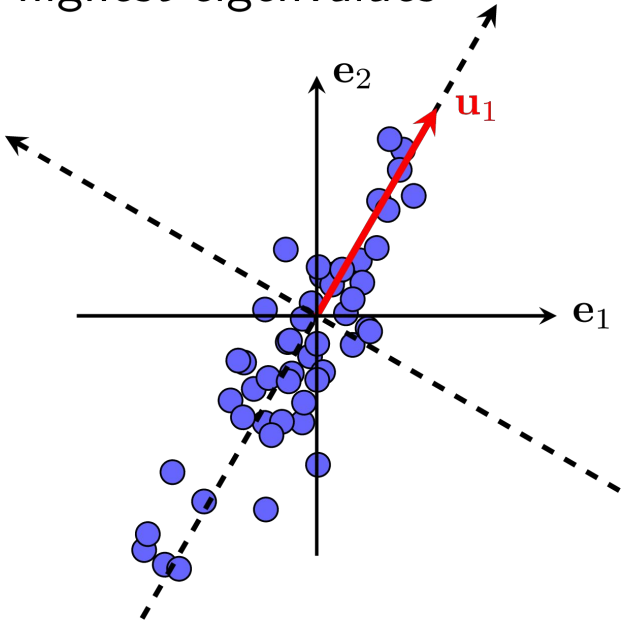

6. Project data to selected eigenvectors.

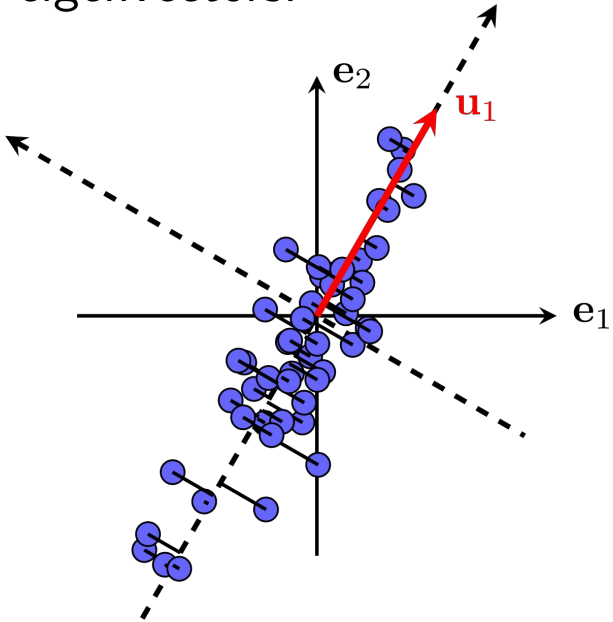

7. Obtain projected points in low dimension.

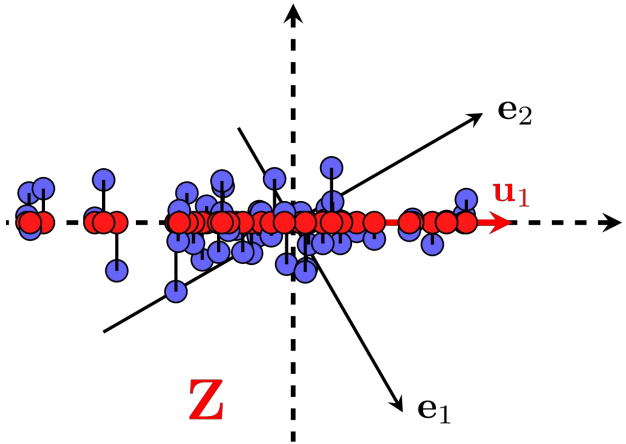

Chọn số chiều K

- Xác định **K** là dựa trên việc *lượng thông tin muốn giữ lại* hay *tổng phương sai* được giữ lại. Trong đó, tổng phương sai của dữ liệu là bằng **tổng các trị riêng** của ma trận hiệp phương sai. Vậy ta có thể coi biểu thức:

$$r_K = \frac{\sum_{1=1}^{K} \lambda_i}{\sum_{j=1}^{D} \lambda_j}$$

  là lượng thông tin được giữ lại khi số chiều dữ liệu mới sau PCA là K.

- Như vậy, giả sử ta muốn giữ lại 90% dữ liệu, ta chỉ cần chọn K là số tự nhiên nhỏ nhất sao cho $r_K \geq 0.90$

PCA Visualization

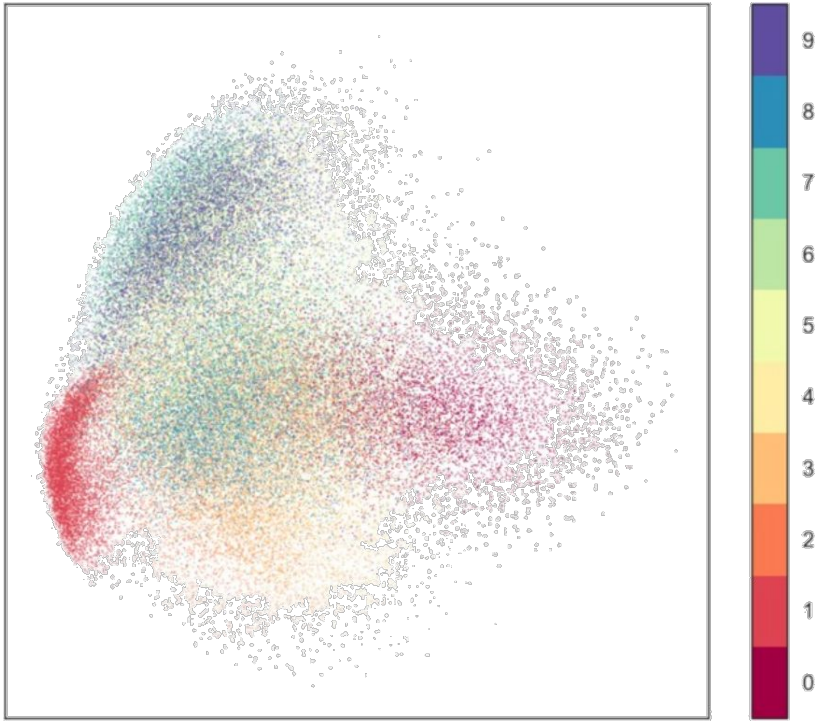

MNIST digits

Manifold Learning

Khái niệm: Giả định dữ liệu nằm trên một **manifold** thấp chiều trong không gian cao chiều.

Các kỹ thuật phổ biến:

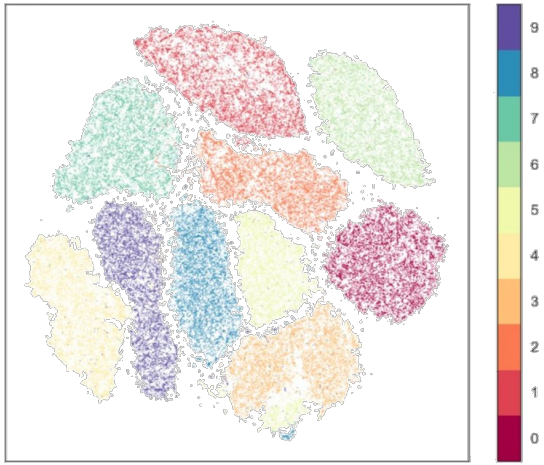

t-SNE

UMAP

t-SNE

Manifold

Introduction

Tên đầy đủ: t-Distributed Stochastic Neighbor Embedding

Mục đích: Giảm chiều dữ liệu, giữ nguyên cấu trúc cục bộ.

Ứng dụng: Trực quan hóa dữ liệu cao chiều, khám phá cấu trúc dữ liệu.

Nguyên lý chính:

- Chuyển đổi dữ liệu cao chiều sang phân phối xác suất P.
- Ánh xạ dữ liệu sang không gian thấp chiều với phân phối Q.
- Tối ưu hóa sự tương đồng giữa P và Q qua KL-divergence.

Các Bước Chính của t-SNE

1. **Tính phân phối P trong không gian cao chiều**:
   - Sử dụng Gaussian để đo lường khoảng cách giữa các điểm.
   - Xác suất p_{ij}: Sự tương tự giữa điểm x_i và x_j.
2. **Tính phân phối Q trong không gian thấp chiều**:
   - Sử dụng phân phối t-Distribution.
   - Xác suất q_{ij}: Sự tương tự trong không gian thấp chiều.
3. **Tối ưu hóa KL-divergence**:
   - Hàm mất mát: $$KL(P||Q) = \sum_i \sum_j p_{ij} \log \left(\frac{p_{ij}}{q_{ij}} \right)$$
   - Sử dụng Gradient Descent để cập nhật tọa độ.

Phân phối trong Không gian Cao Chiều (P)

- **Xác suất p_{ij}:**

$$p_{ij} = \frac{\exp\left(-\|x_i - x_j\|^2 / 2\sigma_i^2\right)}{\sum_{k \neq i} \exp\left(-\|x_k - x_i\|^2 / 2\sigma_k^2\right)}$$

  - σ_i: Độ rộng của Gaussian kernel.
  - $\| x_i - x_j \|$: Khoảng cách giữa điểm x_i và x_j.

Phân phối trong Không gian Thấp Chiều (Q)

- **Xác suất q_{ij}**:

$$q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{k \neq i}(1 + \|y_i - y_k\|^2)^{-1}}$$

  - Sử dụng phân phối t-Distribution để giảm thiểu ảnh hưởng của điểm nhiễu.
- **Đặc điểm**:
  - Phân phối t-Distribution có đuôi dài hơn Gaussian.
  - Giữ nguyên cấu trúc cục bộ hiệu quả.

Tối ưu hóa KL-Divergence

- **Hàm mất mát**:

$$KL(P||Q) = \sum_i \sum_j p_{ij} \log \left(\frac{p_{ij}}{q_{ij}} \right)$$

- **Gradient Descent**:

$$\frac{\partial KL}{\partial y_i} = 4 \sum_j (p_{ij} - q_{ij}) \cdot (y_i - y_j) \cdot (1 + \|y_i - y_j\|^2)^{-1}$$

- **Cập nhật tọa độ**:

$$y_i^{new} = y_i^{old} - \eta \cdot \frac{\partial KL}{\partial y_i}$$

Examples

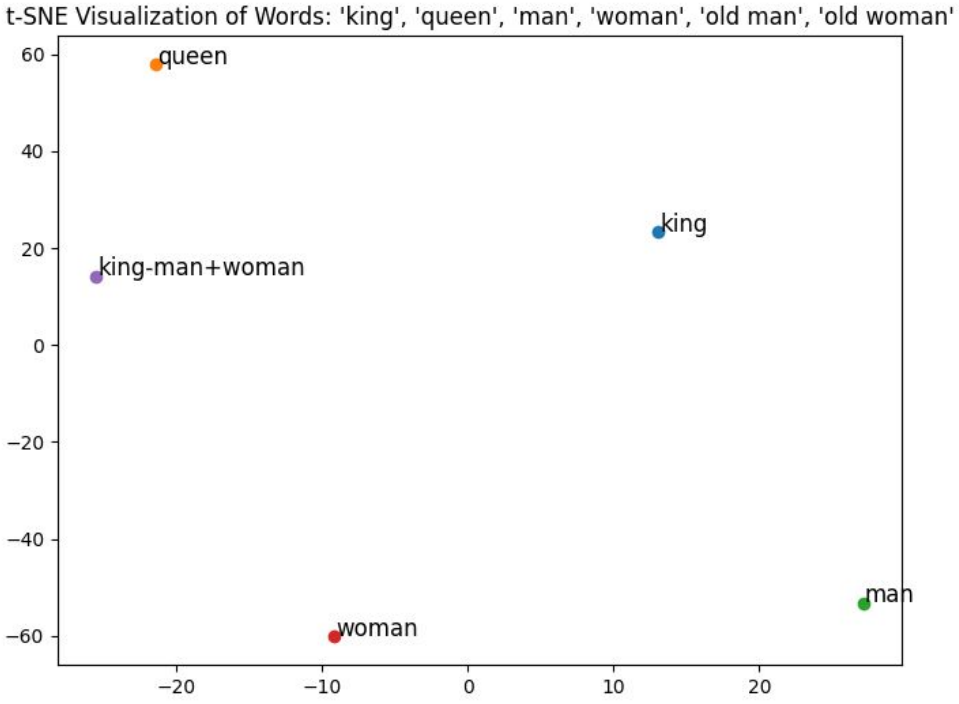
t-SNE Visualization of Words: 'king', 'queen', 'man', 'woman', 'old man', 'old woman'
queen
king
king-man+woman
man
woman
60
40
20
0
−20
−40
−60
−20
−10
0
10
20

Examples

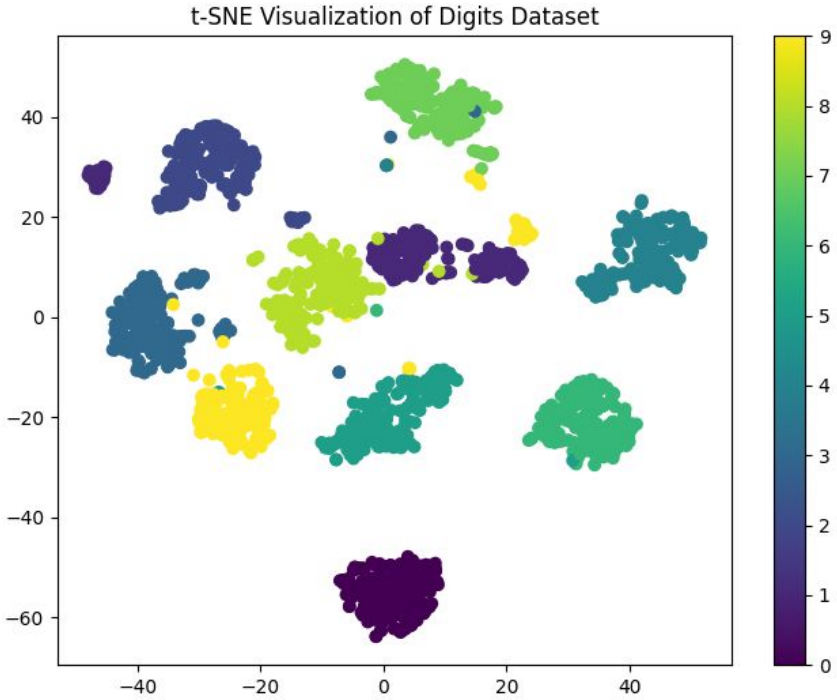
t-SNE Visualization of Digits Dataset
40
20
0
−20
−40
−60
−40
−20
0
20
40
9
8
7
6
5
4
3
2
1
0

Autoencoder

Neural Network

Autoencoders

Khái niệm: Sử dụng mạng neuron để học các biểu diễn nén của dữ liệu đầu vào.
Phân loại:

- **Basic Autoencoders:** Học biểu diễn thấp chiều thông qua mạng encoder-decoder.
- **Sparse Autoencoders:** Thêm ràng buộc thưa thớt để học các đặc trưng quan trọng.
- **Denoising Autoencoders:** Học biểu diễn ổn định bằng cách khử nhiễu.
- **Variational Autoencoders (VAEs):** Mô hình hóa không gian tiềm ẩn (latent space) bằng phân phối xác suất.

Autoencoder

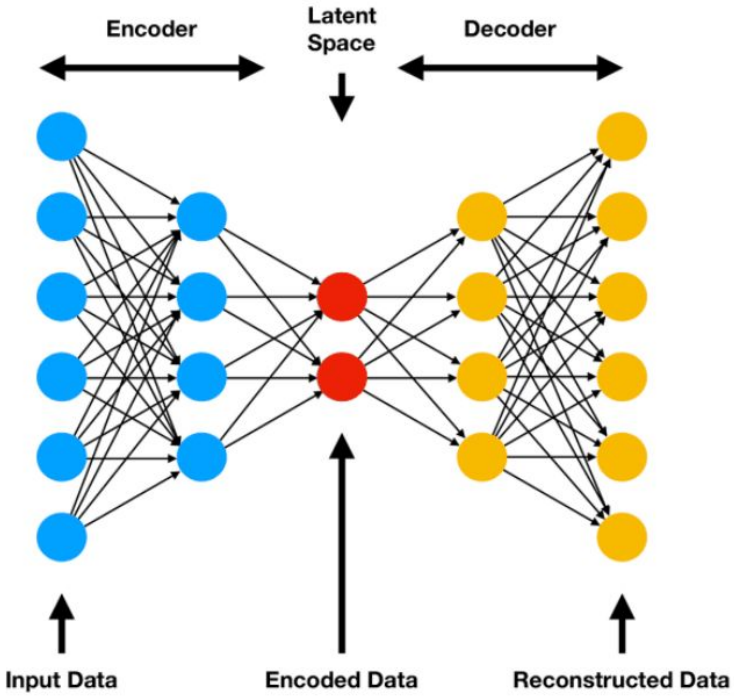

https://www.geeksforgeeks.org/types-of-autoencoders/

Summary

Kỹ thuật	Ưu điểm	Hạn chế	Ứng dụng
Feature Selection	Đơn giản, dễ hiểu	Có thể bỏ sót đặc trưng quan trọng	Phân loại, hồi quy
Matrix Factorization	Giảm nhiễu hiệu quả	Không xử lý tốt cấu trúc phi tuyến	Phân tích dữ liệu
Manifold Learning	Bảo toàn cấu trúc phi tuyến	Tốn tài nguyên, nhạy cảm với siêu tham số	Trực quan hóa dữ liệu phức tạp
Autoencoders	Mô hình hóa linh hoạt	Yêu cầu nhiều dữ liệu	Nén dữ liệu, tái tạo dữ liệu

References

[1] https://cloud.google.com/discover/what-is-unsupervised-learning?hl=en

[2] https://machinelearningmastery.com/dimensionality-reduction-for-machine-learning/

[3] https://www.geeksforgeeks.org/dimensionality-reduction/

[4] https://blog.dataiku.com/dimensionality-reduction-how-it-works-in-plain-english

[5] https://developers.google.com/machine-learning/crash-course/embeddings/embedding-space

[6] https://www.youtube.com/watch?v=NEaUSP4YerM