Semi-Supervised Learning

Machine Learning

Objectives

- Hiểu khái niệm và vai trò của học bán giám sát.
- Nắm được các giả định cơ bản và ứng dụng thực tiễn.
- Tìm hiểu các phương pháp phổ biến:
  - Transductive Learning
  - Inductive Learning
- Thực hành áp dụng học bán giám sát trên bài toán thực tế.

Introduction

- **Chi phí dữ liệu có nhãn:** Cao và khó thu thập.
- **Dữ liệu không nhãn:** Dễ thu thập và thường sẵn có.

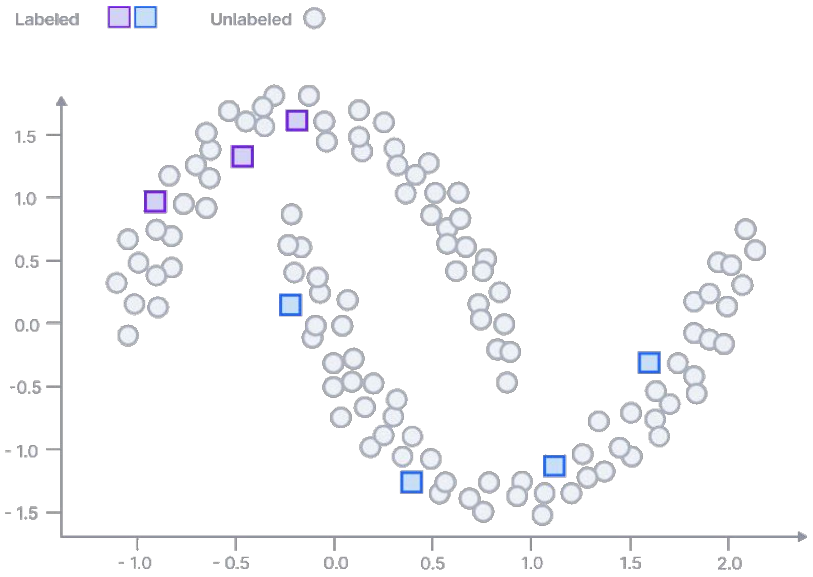

Source: *https://www.v7labs.com/blog/semi-supervised-learning-guide*

Introduction

- **Học giám sát:** Chỉ dùng dữ liệu có nhãn.

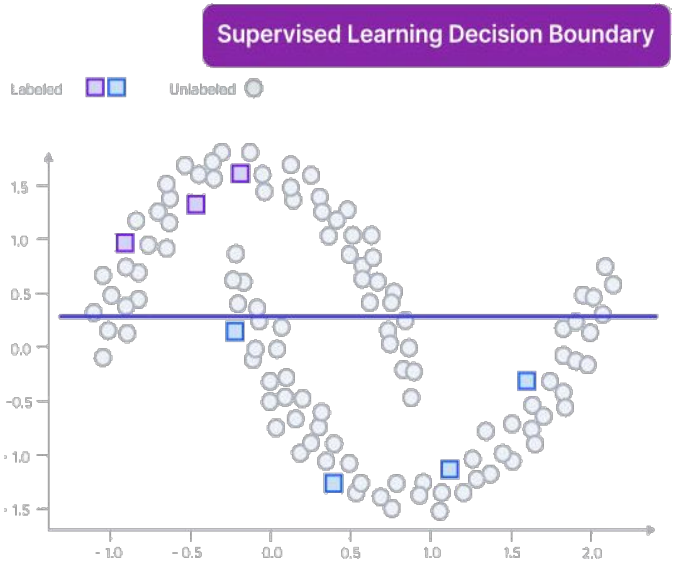

- **Học không giám sát:** Khai thác mẫu trong dữ liệu không nhãn.

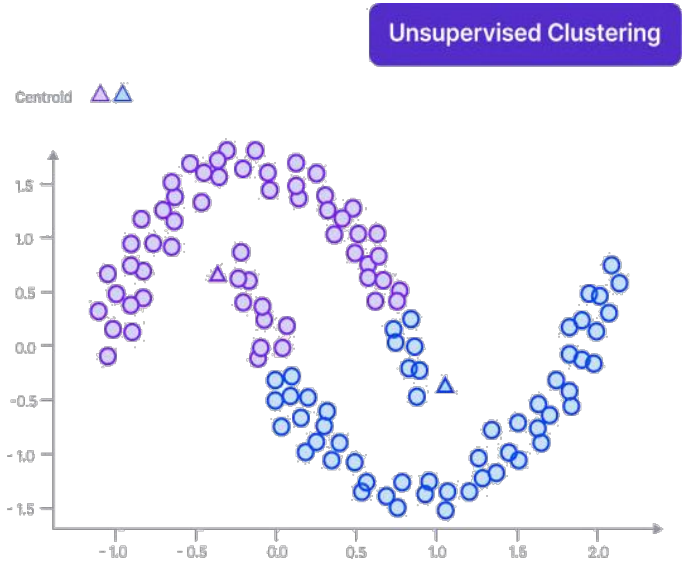

Source: *https://www.v7labs.com/blog/semi-supervised-learning-guide*

Introduction

- **Học bán giám sát:** Kết hợp dữ liệu có nhãn (labeled data) và không nhãn (unlabeled data).
- **Mục tiêu:** Tăng cường hiệu suất mô hình khi dữ liệu có nhãn hạn chế.

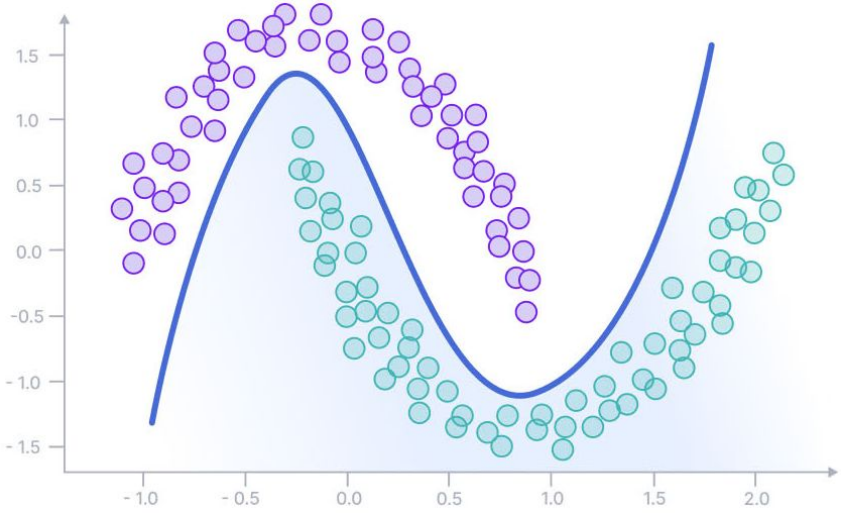

Source: *https://www.v7labs.com/blog/semi-supervised-learning-guide*

Key Assumptions

1. Smoothness / Continuity Assumption

- Dữ liệu gần nhau có cùng nhãn.

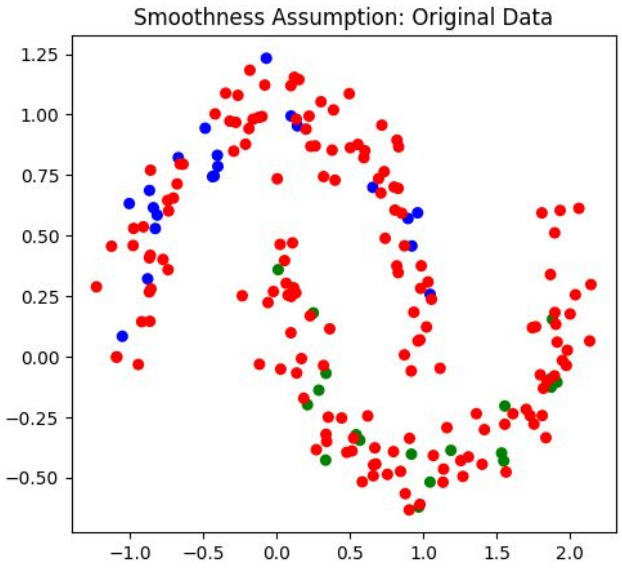

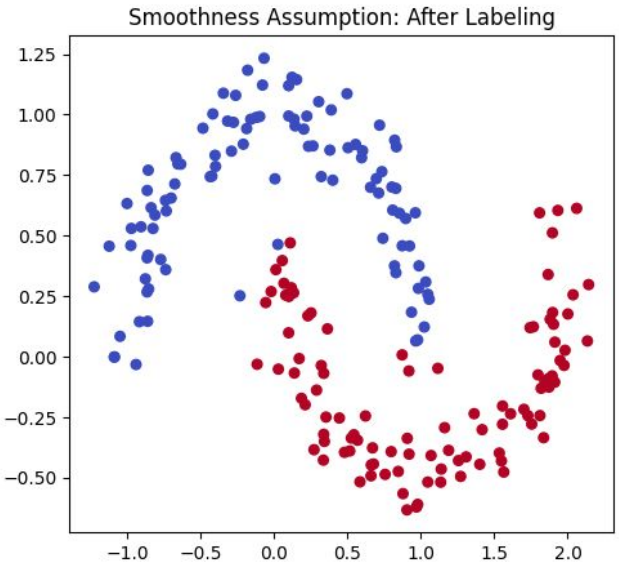

Key Assumptions

2. Cluster / Low-Density Assumption

- Dữ liệu được nhóm thành cụm; các điểm trong cụm có nhãn giống nhau.

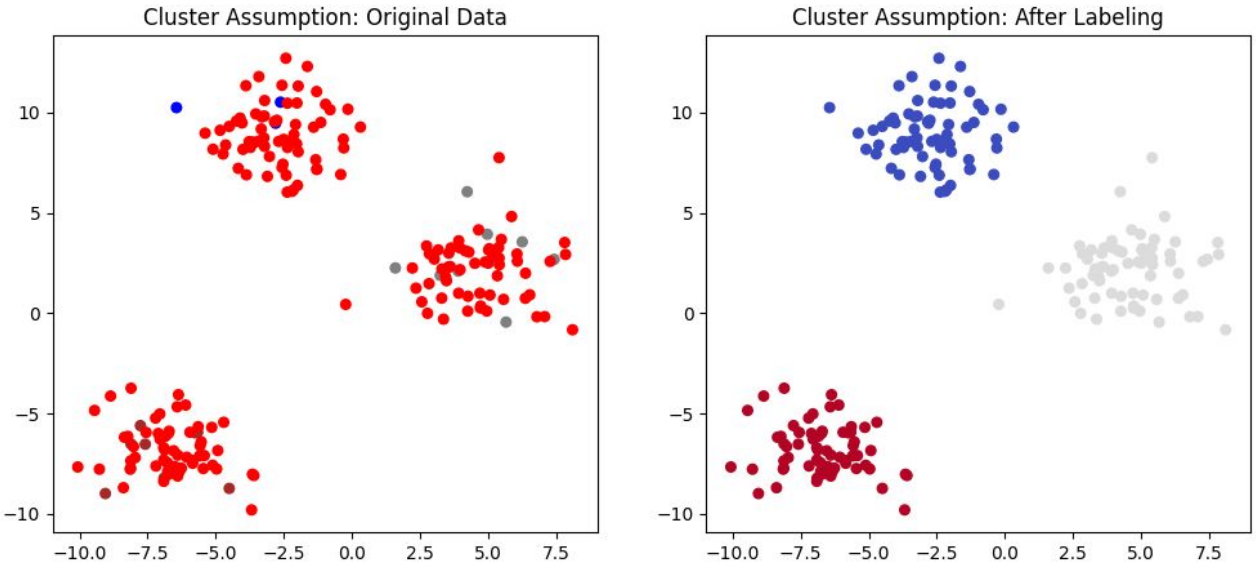

Key Assumptions

3. Manifold Assumption

- Dữ liệu nằm trên manifold có chiều thấp hơn không gian gốc.

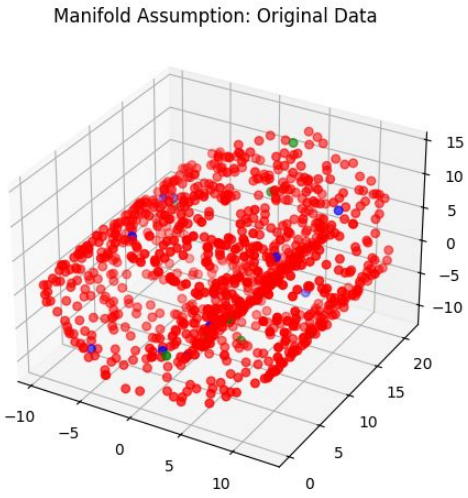

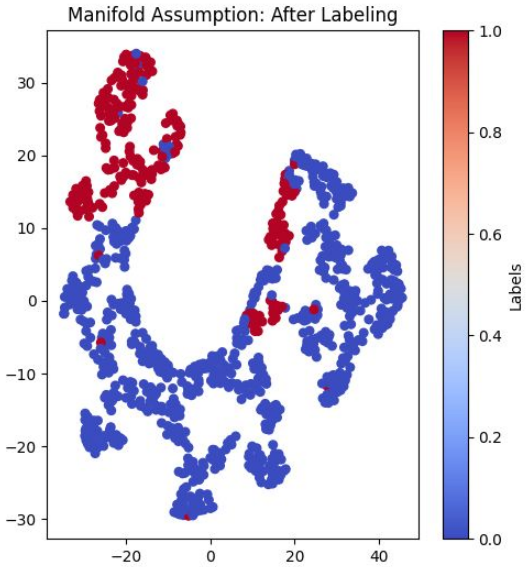

Semi-Supervised Learning Methods

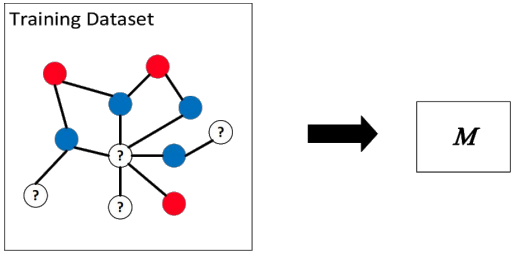

Transductive Learning

- Chỉ tập trung vào dữ liệu hiện có mà không tổng quát hóa cho dữ liệu chưa biết.

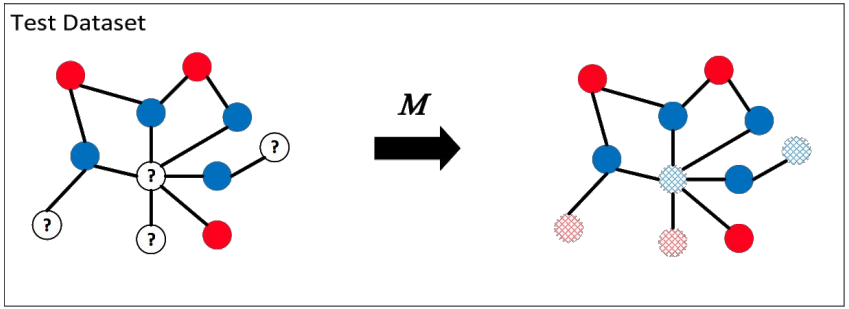

Inductive Learning

- Tạo ra một mô hình tổng quát có khả năng ứng dụng trên dữ liệu mới, chưa từng thấy trước đó.

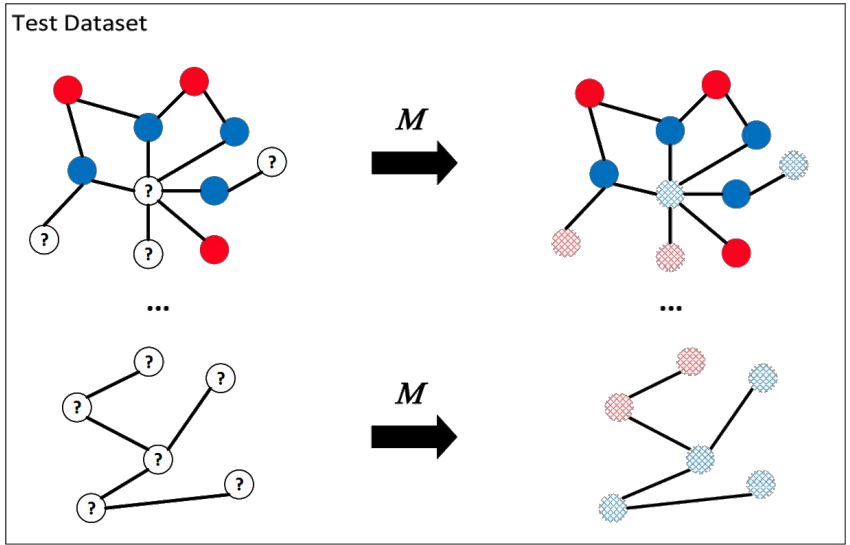

Transductive Learning - Graph-Based Learning

- Xây dựng đồ thị, các nút là dữ liệu, cạnh biểu thị độ tương đồng.
- Truyền nhãn từ dữ liệu có nhãn đến dữ liệu không nhãn.

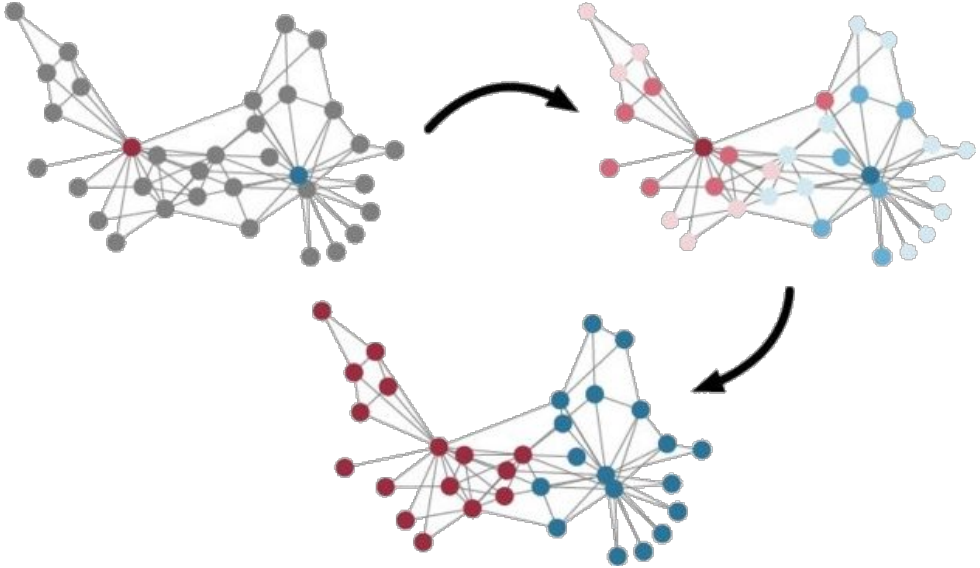

Graph-Based Learning - Label Propagation

Bước 1. Xây dựng đồ thị dựa vào ma trận trọng số W

- Mỗi hàng và cột tương ứng với một điểm dữ liệu.
- Trọng số giữa hai điểm là độ tương đồng.

Bước 2. Chuẩn hóa ma trận W thành ma trận chuyển tiếp P:

Bước 3. Truyền nhãn:

- Khởi tạo nhãn: Y_0
- Cập nhật nhãn (lặp): Nhãn mới $Y_{t+1} = P.Y_t$
- Lặp lại quá trình truyền nhãn cho đến khi:
    - Nhãn hội tụ (không thay đổi qua các vòng lặp).
    - Hoặc đạt đến số vòng lặp tối đa.

Ví dụ - Label Propagation

- Tập dữ liệu:

Điểm dữ liệu	Tọa độ (x, y)	Nhãn ban đầu
x1	(1.0, 1.0)	0
x2	(4.0, 4.0)	1
x3	(1.5, 1.2)	-1
x4	(3.8, 4.1)	-1
x5	(1.2, 0.9)	-1
x6	(4.1, 3.9)	-1

Ví dụ - Label Propagation

- Tính ma trận khoảng cách D giữa các điểm dựa trên khoảng cách Euclidean:

$$D[i,j] = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2}$$

Điểm	x1	x2	x3	x4	x5	x6
x1	0.0	4.24	0.54	4.08	0.22	4.18
x2	4.24	0.0	3.70	0.28	4.20	0.22
x3	0.54	3.70	0.0	3.58	0.45	3.70
x4	4.08	0.28	3.58	0.0	4.03	0.22
x5	0.22	4.20	0.45	4.03	0.0	4.10
x6	4.18	0.22	3.70	0.22	4.10	0.0

Ví dụ - Label Propagation

- Xây dựng ma trận trọng số W với Gaussian kernel (σ = 1.0):

$$W[i,j] = \exp\left(-\frac{D[i,j]^2}{2\sigma^2}\right)$$

Điểm	x1	x2	x3	x4	x5	x6
x1	1.00	0.02	0.79	0.02	0.98	0.02
x2	0.02	1.00	0.03	0.97	0.02	0.98
x3	0.79	0.03	1.00	0.03	0.82	0.03
x4	0.02	0.97	0.03	1.00	0.02	0.98
x5	0.98	0.02	0.82	0.02	1.00	0.02
x6	0.02	0.98	0.03	0.98	0.02	1.00

Ví dụ - Label Propagation

- Xây dựng ma trận trọng số W với Gaussian kernel (σ = 1.0):

$$W[i,j] = \exp\left(-\frac{D[i,j]^2}{2\sigma^2}\right)$$

Điểm	x1	x2	x3	x4	x5	x6
x1	0.49	0.01	0.39	0.01	0.49	0.01
x2	0.01	0.49	0.01	0.49	0.01	0.49
x3	0.39	0.01	0.39	0.01	0.39	0.01
x4	0.01	0.49	0.01	0.49	0.01	0.49
x5	0.49	0.01	0.39	0.01	0.49	0.01
x6	0.01	0.49	0.01	0.49	0.01	0.49

Ví dụ - Label Propagation

- Chuẩn hóa ma trận trọng số W để tạo ma trận chuyển tiếp P:

$$P[i,j] = \frac{W[i,j]}{\sum_k W[i,k]}$$

Điểm	x1	x2	x3	x4	x5	x6
x1	0.49	0.01	0.39	0.01	0.49	0.01
x2	0.01	0.49	0.01	0.49	0.01	0.49
x3	0.39	0.01	0.39	0.01	0.39	0.01
x4	0.01	0.49	0.01	0.49	0.01	0.49
x5	0.49	0.01	0.39	0.01	0.49	0.01
x6	0.01	0.49	0.01	0.49	0.01	0.49

Ví dụ - Label Propagation

Truyền nhãn

- Khởi tạo nhãn:

  $Y_0 = [1,0,0,0,0,0]^\top$ cho x1, và

  $Y_0 = [0,1,0,0,0,0]^\top$ cho x2.

- Lặp:

$$Y_{t+1} = P \cdot Y_t$$

Điểm	Nhãn cuối cùng
x1	0
x2	1
x3	0
x4	1
x5	0
x6	1

Inductive Learning - Self-Training

1. Huấn luyện mô hình trên dữ liệu có nhãn.
2. Dự đoán nhãn giả (pseudo−labels) cho dữ liệu không nhãn dựa trên độ tin cậy.
3. Gắn nhãn giả cho những điểm có độ tin cậy cao hơn ngưỡng (threshold=0.8).
4. Lặp lại quá trình cho đến khi không còn nhãn nào có thể gán hoặc đạt số vòng lặp tối đa.

Inductive Learning - Co-Training

1. Khởi tạo mô hình
2. Quá trình Co-Training:
   a. Mỗi mô hình huấn luyện trên dữ liệu có nhãn ở các view độc lập.
   b. Sau đó, mỗi mô hình sẽ gán nhãn cho dữ liệu không nhãn nếu độ tin cậy của nhãn giả vượt qua ngưỡng threshold.
   c. Các nhãn giả này sau đó được gán cho dữ liệu không nhãn.

Inductive Learning - Consistency Regularization

1. **Huấn luyện mô hình** trên dữ liệu có nhãn.
2. **Dự đoán nhãn giả:** Dự đoán nhãn cho dữ liệu không nhãn với ngưỡng tin cậy.
3. **Thêm nhiễu Gaussian:** Thêm nhiễu vào dữ liệu không nhãn để tạo ra phiên bản bị nhiễu.
4. **So sánh độ nhất quán:** So sánh nhãn dự đoán giữa dữ liệu gốc và dữ liệu bị nhiễu. Nếu độ tin cậy cho cả hai phiên bản đều cao, thì nhãn được xem là nhất quán.

Semi-Supervised Learning Workflow

1. Chuẩn bị dữ liệu: Phân chia dữ liệu có nhãn và không nhãn.

2. Chọn phương pháp:

- **Co-Training**: Tốt cho bài toán có **đặc trưng bổ sung** rõ ràng.
- **Self-Training**: Đơn giản và hiệu quả khi có **một ít nhãn chính xác**.
- **Consistency Regularization**: Lý tưởng khi dữ liệu có thể áp dụng **augmentation tự nhiên** (e.g., ảnh, âm thanh).
- **Graph-Based Learning**: Mạnh mẽ khi dữ liệu có thể biểu diễn thành **đồ thị với quan hệ rõ ràng** giữa các điểm dữ liệu.

3. Huấn luyện mô hình: Kết hợp cả dữ liệu có nhãn và không nhãn.

4. Đánh giá: So sánh hiệu suất trước và sau khi thêm dữ liệu không nhãn.

Practice Session

- **Bài toán:** Phân loại chữ số viết tay (MNIST) với dữ liệu có nhãn bị giảm bớt (10%).
- **Công cụ:** PyTorch hoặc TensorFlow.
- **Các bước:**
  1. Tải dữ liệu và tiền xử lý.
  2. Huấn luyện mô hình Self-Training.
  3. Đánh giá hiệu suất trước và sau khi thêm dữ liệu không nhãn.

Summary and Discussion

Tóm Tắt:

- Học bán giám sát kết hợp dữ liệu có nhãn và không nhãn để cải thiện hiệu suất mô hình.
- Các phương pháp phổ biến: Self-Training, Co-Training, Graph-Based Learning, Consistency Regularization.
- Ứng dụng rộng rãi trong NLP, thị giác máy tính, và y học.

Câu Hỏi Ôn Tập:

- Học bán giám sát khác gì so với học giám sát?
- Trình bày quy trình và ứng dụng của Self-Training.
- Khi nào nên sử dụng Graph-Based Learning?

References

[1] https://www.ibm.com/topics/semi-supervised-learning

[2] https://scikit-learn.org/1.5/modules/semi_supervised.html

[3] https://blog.roboflow.com/what-is-semi-supervised-learning/

[4] https://www.v7labs.com/blog/semi-supervised-learning-guide

[5] https://encord.com/blog/active-learning-machine-learning-guide/

[6]