Logistic Regression

Machine Learning

NỘI DUNG

1. Giới thiệu
2. Hàm mất mát
3. Tối ưu hóa hàm mất mát

1. Giới thiệu về Bài Toán Phân Loại

- Dự đoán nhãn (**0** hoặc **1**) cho một mẫu dữ liệu.

Ví dụ: Dự đoán kết quả thi là **Pass** hoặc **Fail**.

- **Input:** Số giờ học trong ngày.
- **Output:** Xác suất kết quả thi là **Pass** (Pass = 1, Fail = 0).

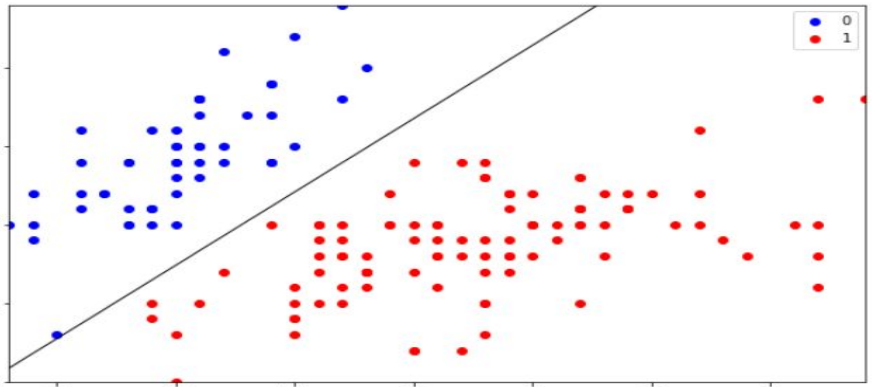

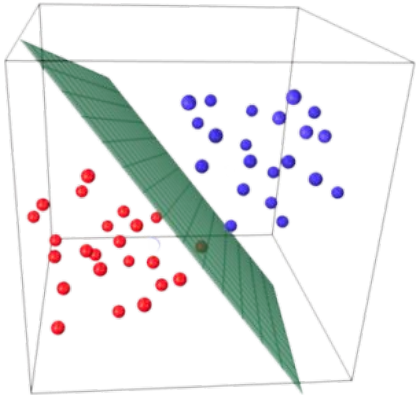

Linear Regression trong Phân Loại

Mô hình:

$$y = -0.15 + 0.23\,x$$

- **y:** giá trị dự đoán, **x:** số giờ học.

Ví dụ dự đoán:

- Số giờ học: 0.5 → y = -0.04
- Số giờ học: 3.0 → y = 0.55
- Số giờ học: 5.5 → y = 1.14

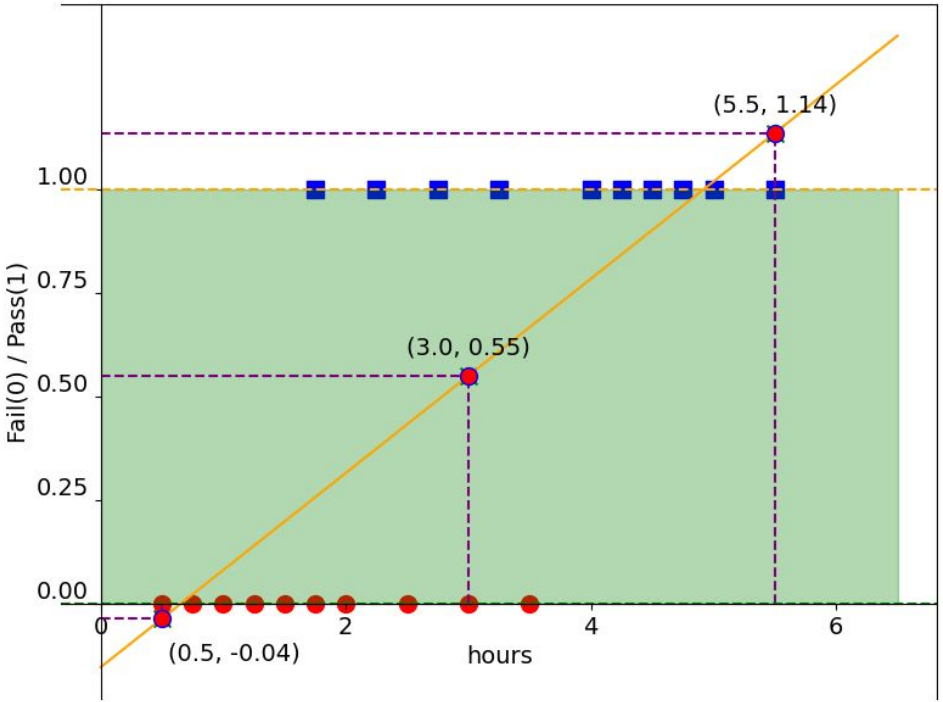

Các Vấn Đề với Linear Regression

- **Dự đoán ngoài phạm vi** (0, 1): Dự đoán -0.04, 1.14 không có ý nghĩa cho xác suất.

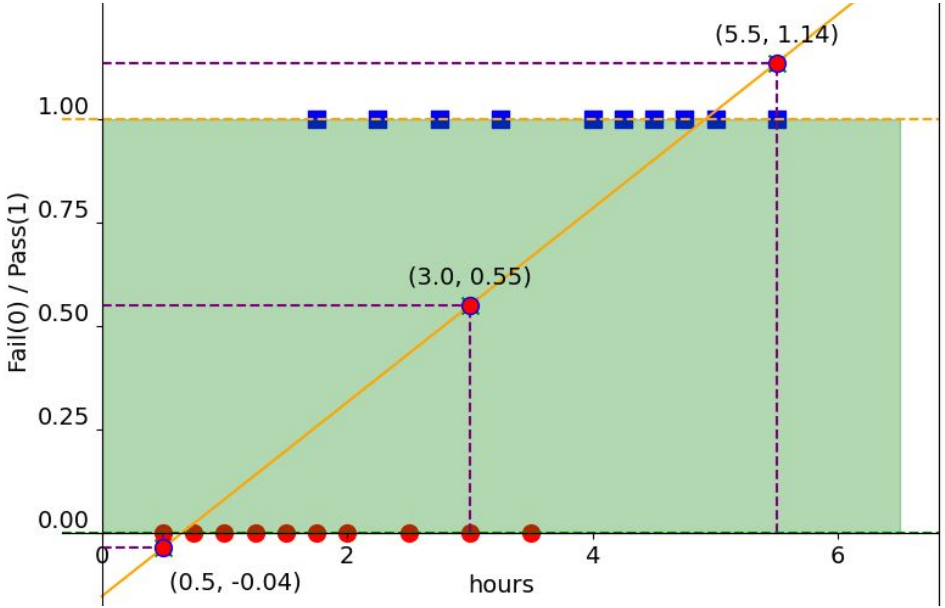

Các Vấn Đề với Linear Regression

- **Không thể tạo ra ranh giới phân loại rõ ràng**: Không có ngưỡng xác định cho việc phân loại

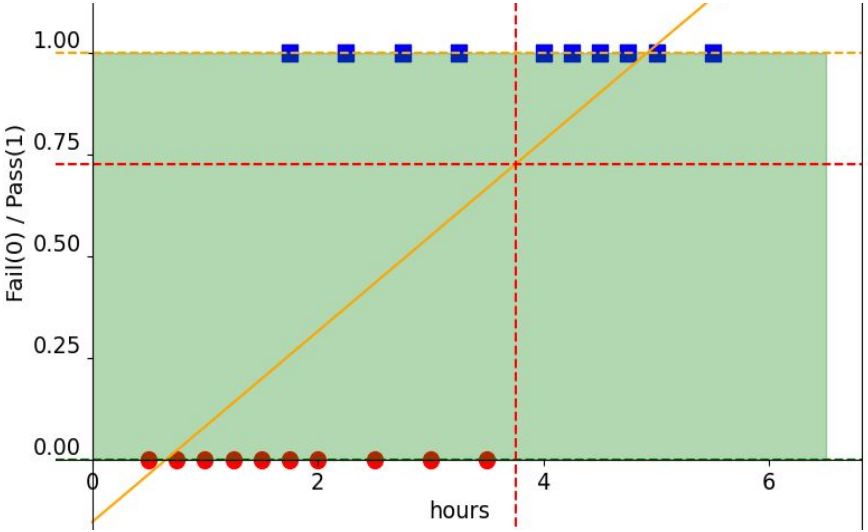

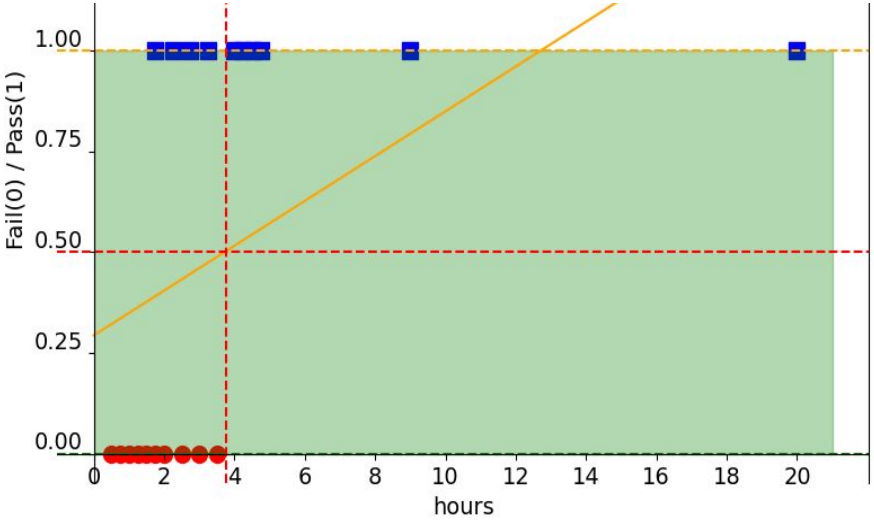

Cần một Giải Pháp Mới

- Cần giới hạn đầu ra trong phạm vi (0, 1) để biểu diễn xác suất.
- Cần ranh giới phân loại rõ ràng.

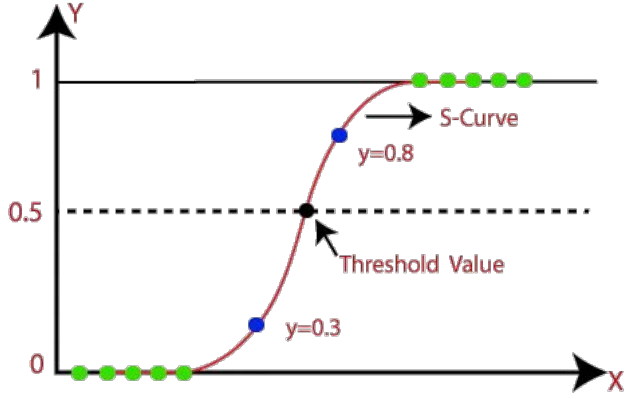

***Image source**: javatpoint.com*

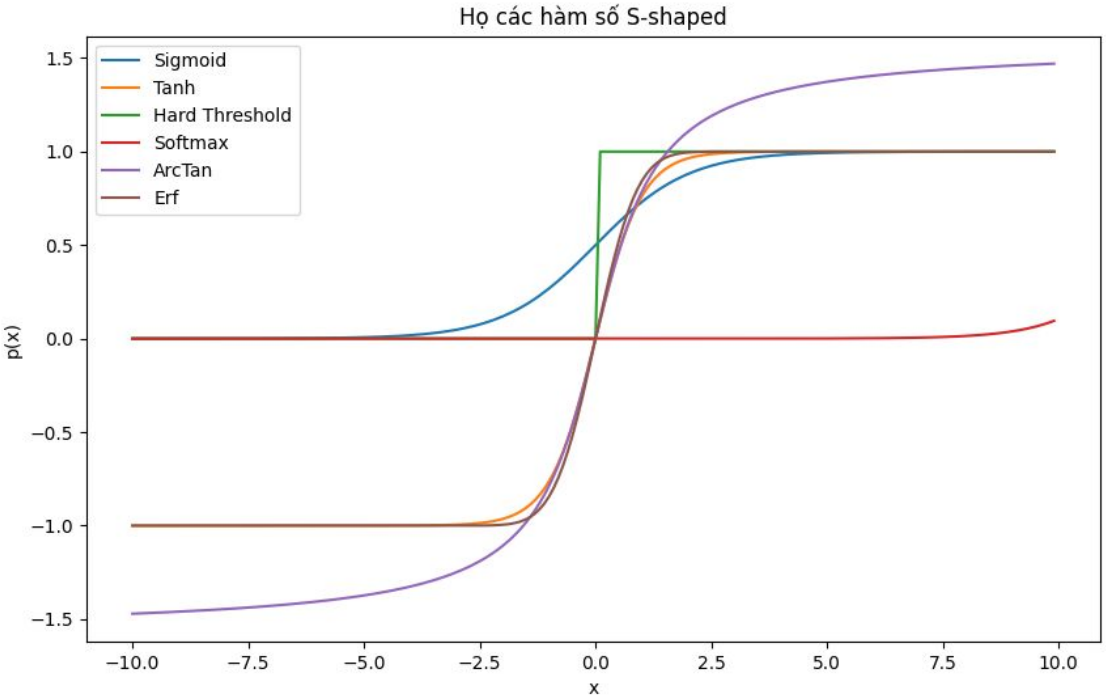

Hàm Sigmoid

- Công thức hàm sigmoid:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

  - Với $z = w_0 + w_1 x$
- Hàm sigmoid biến giá trị dự đoán thành xác suất trong khoảng (0, 1).

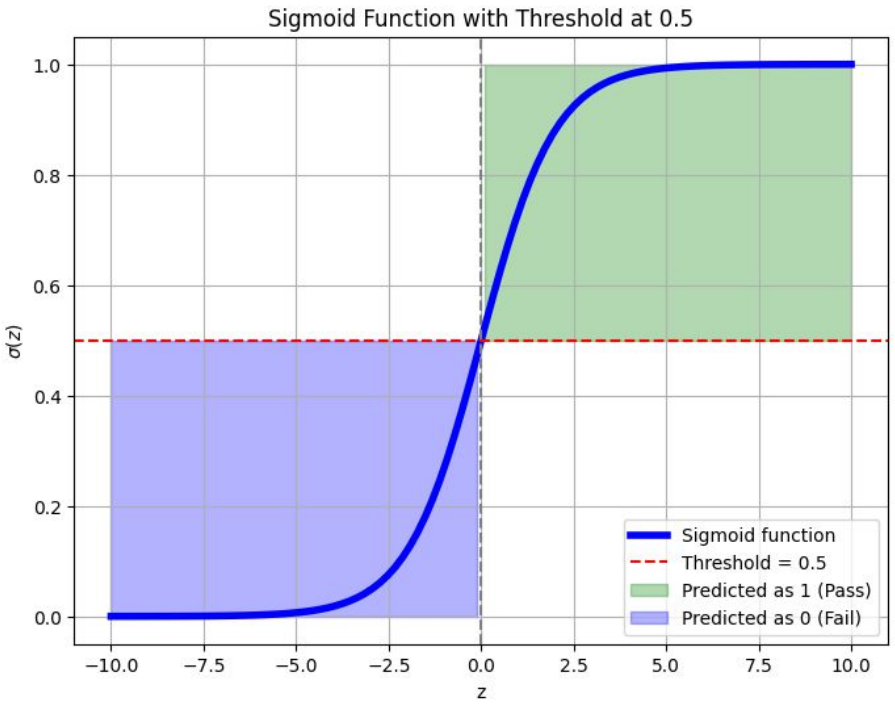

Hàm Sigmoid

- Công thức hàm sigmoid:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

  - Với $z = w_0 + w_1 x$

- Công thức tính đạo hàm đơn giản:

$$\sigma'(z) = \sigma(z) \cdot (1 - \sigma(z))$$

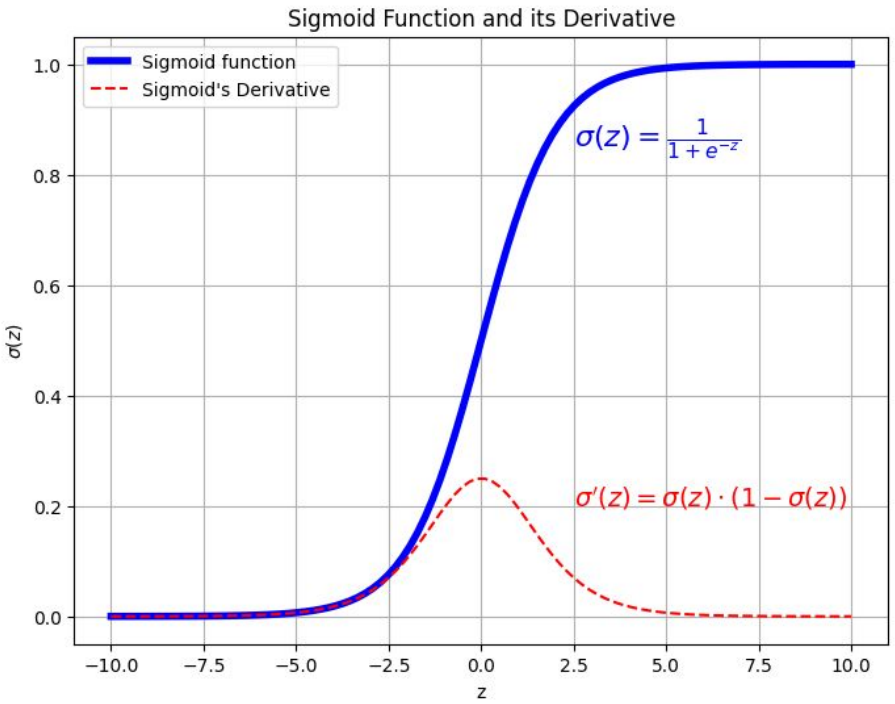

2. Xây dựng hàm mất mát cho Logistic Regression

- **Dự đoán (xác suất):**

$$P(y = 1 \mid x, w) = \sigma(z) = \frac{1}{1 + e^{-z}}$$

với $z = w_0 + w_1 x_1 + \cdots + w_n x_n$

- **Đầu ra:** Xác suất thuộc nhóm 1 (*ví dụ:* pass, spam).

  Ví dụ:

  - Kết quả thi sau khi học 4 giờ mỗi ngày → Xác suất = 0.75 (75%).
  - Email chứa 10 từ spam → Xác suất = 0.69 (69%).

Dự đoán cho 1 điểm dữ liệu

- **Xác suất** rằng y = 1**:**

$$P(y_i = 1 \mid x_i, w) = \sigma(z_i)$$

- **Xác suất** rằng y = 0**:**

$$P(y_i = 0 \mid x_i, w) = 1 - \sigma(z_i)$$

- **Hàm dự đoán tổng quát:**

$$P(y_i \mid x_i, w) = \sigma(z_i)^{y_i}(1 - \sigma(z_i))^{(1-y_i)}$$

Dự đoán cho N điểm dữ liệu

- **Xác suất tổng quát cho tập dữ liệu huấn luyện:**

$$P(y \mid x, w) = \prod_{i=1}^{N} P(y_i \mid x_i, w)$$

- **Tối ưu hóa:** Tìm *w* để cực đại *P(y | x,w)*

$$w = \arg\max_{w} P(y \mid x, w)$$

hay

$$w = \arg\max_{w} \log(P(y \mid x, w))$$

Hàm mất mát

$$J(\mathbf{w}) = -\log P(\mathbf{y}|\mathbf{X};\mathbf{w})$$
$$= -\sum_{i=1}^{N}(y_i \log z_i + (1-y_i)\log(1-z_i))$$

trong đó:

- z_i là một hàm số của w
- vế phải có tên gọi là cross entropy

Tối ưu hàm mất mát

- Sử dụng phương pháp Stochastic Gradient Descent (SGD). Hàm mất mát với chỉ một điểm dữ liệu (x_i, y_i) là:

$$J(\mathbf{w}; \mathbf{x}_i, y_i) = -(y_i \log z_i + (1 - y_i) \log(1 - z_i))$$

- Với đạo hàm: $$\frac{\partial J(\mathbf{w}; \mathbf{x}_i, y_i)}{\partial \mathbf{w}} = (z_i - y_i)\mathbf{x}_i$$

- Công thức cập nhật (thuật toán SGD) cho logistic regression:

$$\mathbf{w} = \mathbf{w} + \eta(y_i - z_i)\mathbf{x}_i$$

Kết Luận

- Logistic Regression giúp giải quyết bài toán phân loại nhị phân tốt hơn nhờ:
  - Giới hạn đầu ra trong khoảng (0, 1).
  - Dự đoán xác suất và áp dụng được cho phân loại.
- **Ứng dụng:** Logistic Regression được sử dụng rộng rãi trong các bài toán như phân loại email spam, phân loại bệnh tật, dự đoán khách hàng tiềm năng.

Tài Liệu Tham Khảo

https://machinelearningcoban.com/