Clustering Algorithms

Machine Learning

What is Clustering?

- Clustering is a method in Unsupervised Learning used to group data points into clusters such that:
  - Data points in the same cluster are highly similar.
  - Data points in different clusters are significantly different.
- **Goal:**
  - Discover hidden patterns or groupings in the data without predefined labels.

Why Clustering?

- To explore and summarize large datasets.
- To discover underlying data structures.

Key Applications

- **Customer Segmentation**: Group customers by behavior to personalize marketing.
- **Document Organization**: Cluster articles, books, or research papers by theme.
- **Image Segmentation**: Separate objects or regions in an image.
- **Anomaly Detection**: Identify fraud or unusual patterns.
- **Genetic Analysis**: Cluster similar DNA sequences for study.

Types of Clustering Algorithms

Partition-based:

- Example: K-means.
- Divides data into k non-overlapping clusters.

Density-based:

- Example: DBSCAN.
- Groups points that are closely packed together and marks outliers as noise.

Hierarchical:

- Example: Agglomerative Clustering.
- Builds a tree of clusters (dendrogram).

Challenges in Clustering

1. **Defining "Similarity"**:
   - Different datasets require different metrics (Euclidean, Manhattan, Cosine).
2. **Choosing k or number of clusters**:
   - How many clusters should the data have?
3. **Handling Outliers**:
   - Noisy or irrelevant data can distort results.
4. **Scalability**:
   - Large datasets may require efficient algorithms.
5. **Interpretability**:
   - How meaningful are the discovered clusters?

K-means

Clustering Algorithms

Introduction

- K-means là một thuật toán **học không giám sát** dùng để phân cụm dữ liệu thành k cụm dựa trên khoảng cách Euclid.
- **Mục tiêu**: Tìm ***k*** cụm thỏa mãn hàm mục tiêu:

$$\text{minimize} \sum_{i=1}^{k} \sum_{x \in C_i} \|x - \mu_i\|^2$$

  - C_i: Các điểm trong cụm i.
  - μ_i: Tâm cụm i.

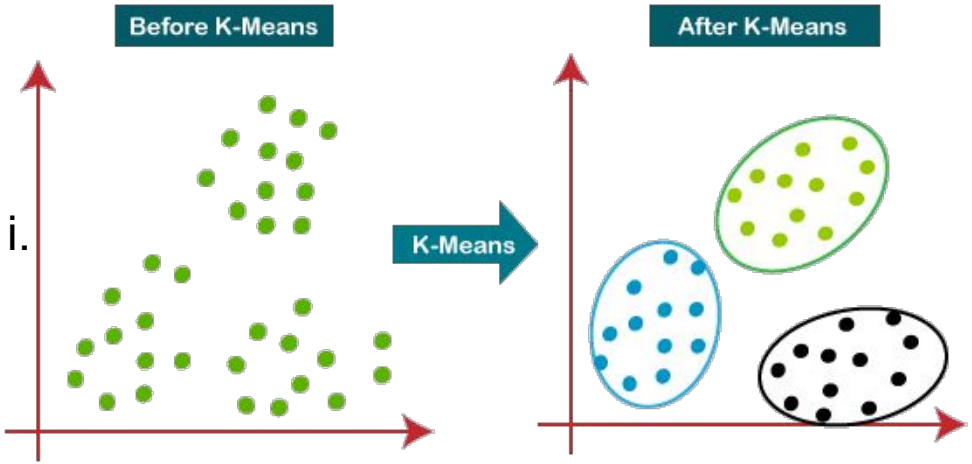

K-means Algorithm

Bước 1: Chọn số cụm k.

Bước 2: Khởi tạo ngẫu nhiên k tâm cụm.

Bước 3: Gán mỗi điểm dữ liệu vào cụm gần nhất dựa trên khoảng cách Euclid.

$$C_i = \{x \mid \|x - \mu_i\|^2 \leq \|x - \mu_j\|^2, \forall j \neq i\}$$

Bước 4: Tính tâm cụm mới dựa trên trung bình các điểm thuộc cụm:

$$\mu_i = \frac{1}{|C_i|} \sum_{x \in C_i} x$$

Bước 5: Lặp lại từ bước (3) đến khi không còn thay đổi hoặc đạt ngưỡng hội tụ.

An Example

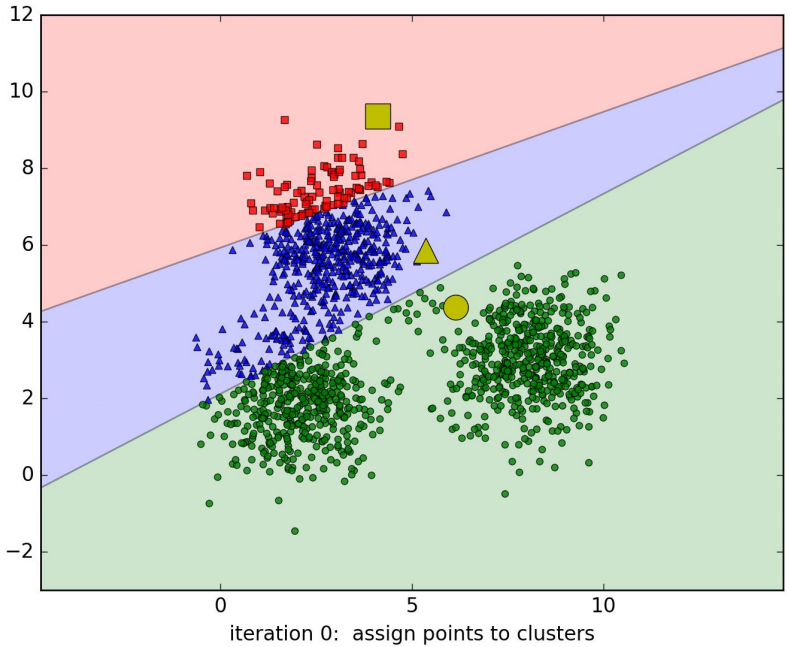

Source: *https://machinelearningcoban.com/2017/01/01/kmeans/*

Disadvantages - Slow Convergence

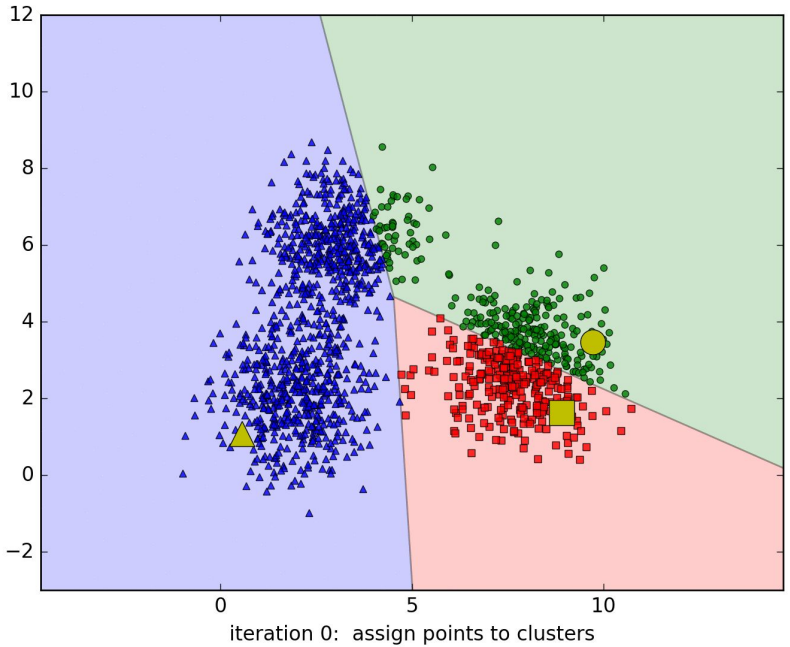

Disadvantages - Bad Results

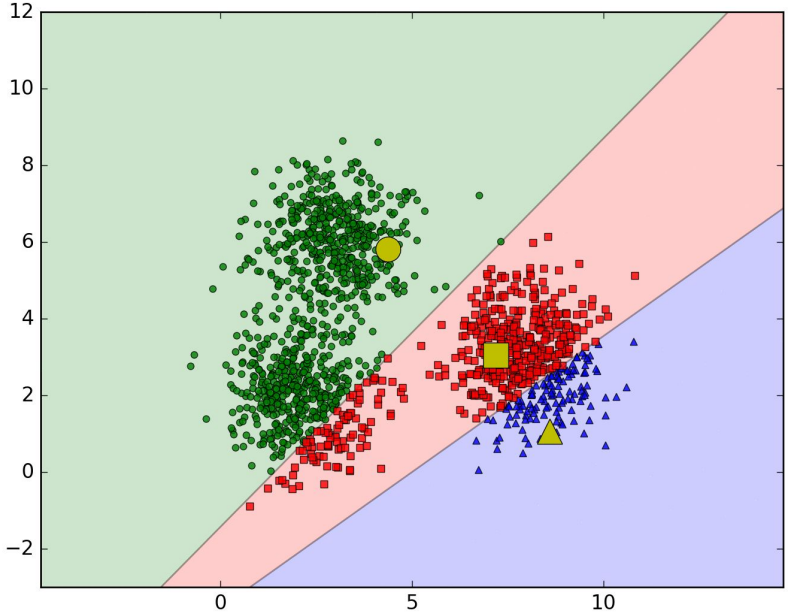

iteration 0: assign points to clusters

Disadvantages - Unbalanced Data

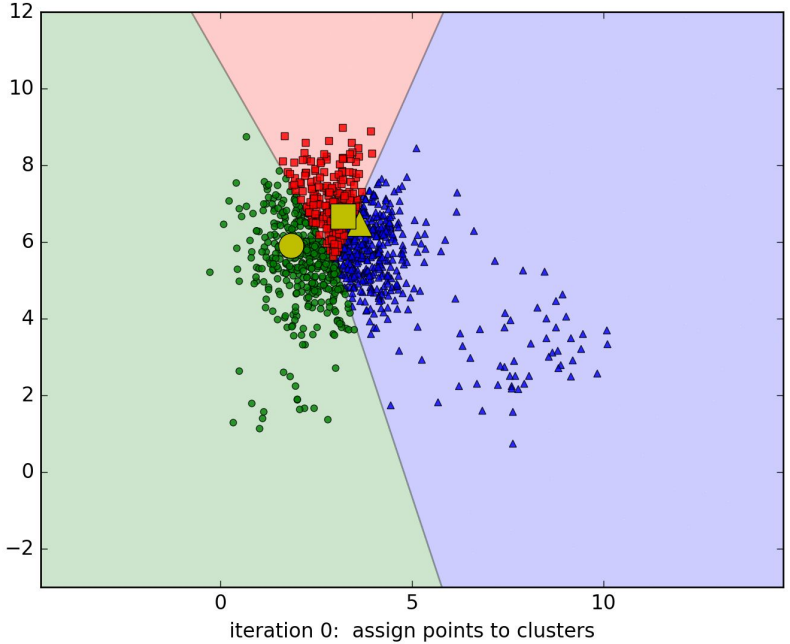

Disadvantages - Flattened shape

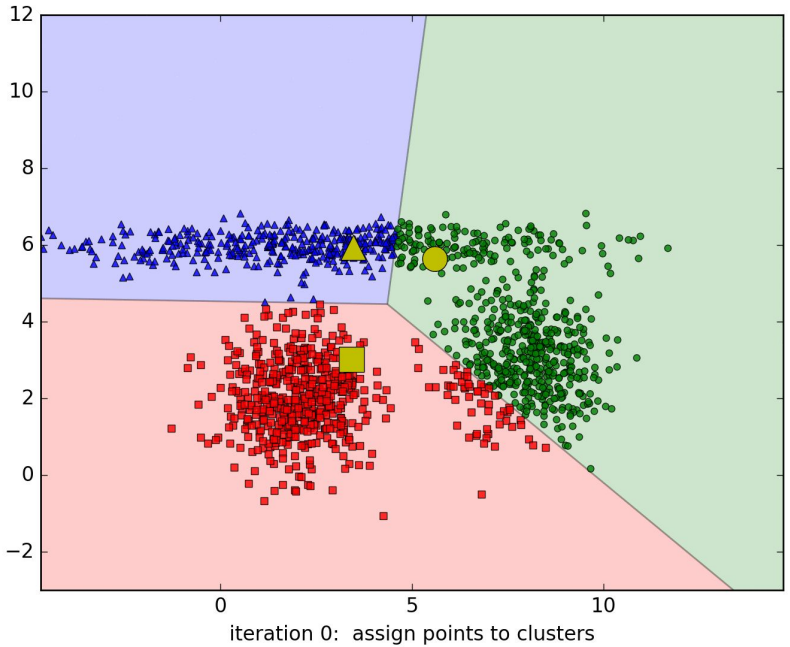

Disadvantages - Within another cluster

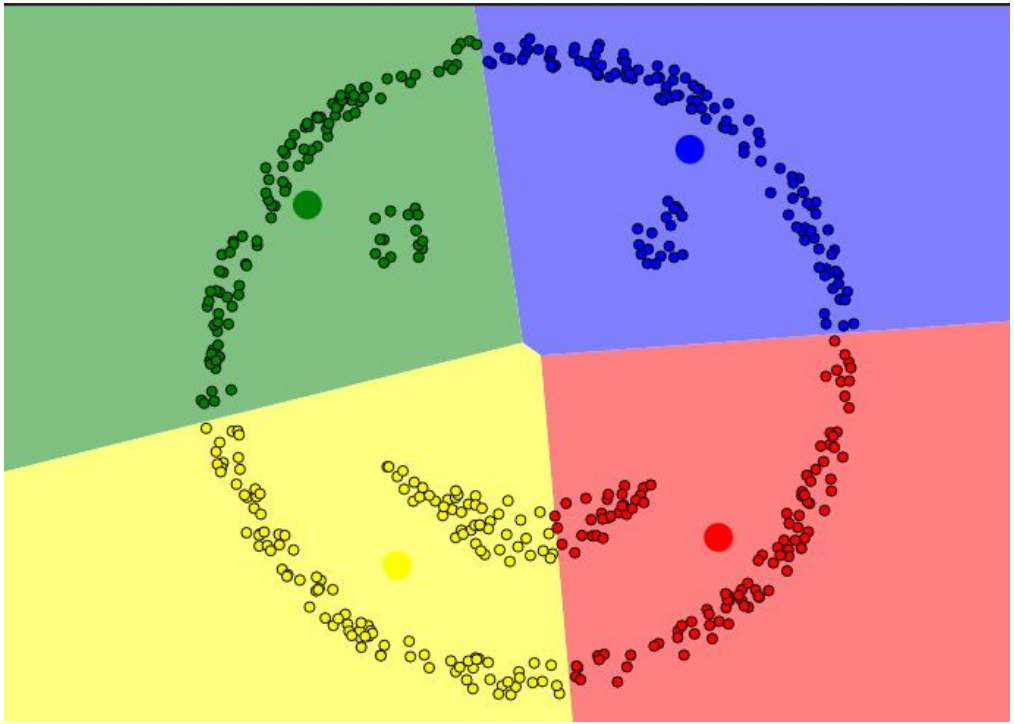

Selecting the optimal k

Phương pháp Elbow (Khuỷu tay):

- Tính tổng khoảng cách nội cụm WCSS (Within Cluster Sum of Squares) cho các giá trị k = 1,2,…,n.
- Chọn k tại điểm gãy trên đồ thị.

Silhouette Score:

- Đánh giá chất lượng phân cụm dựa trên mức độ gần gũi giữa các cụm.

Gap Statistic:

- So sánh hiệu quả phân cụm trên dữ liệu thực và dữ liệu ngẫu nhiên.

Elbow Method

- Tính tổng khoảng cách nội cụm WCSS (Within-Cluster Sum of Squares) cho các giá trị **k** khác nhau.
- Điểm "khuỷu tay" (elbow point) là giá trị k tối ưu, tại đó việc tăng thêm cụm không làm giảm đáng kể WCSS.

$$WCSS = \sum_{i=1}^{k} \sum_{x \in C_i} \|x - \mu_i\|^2$$

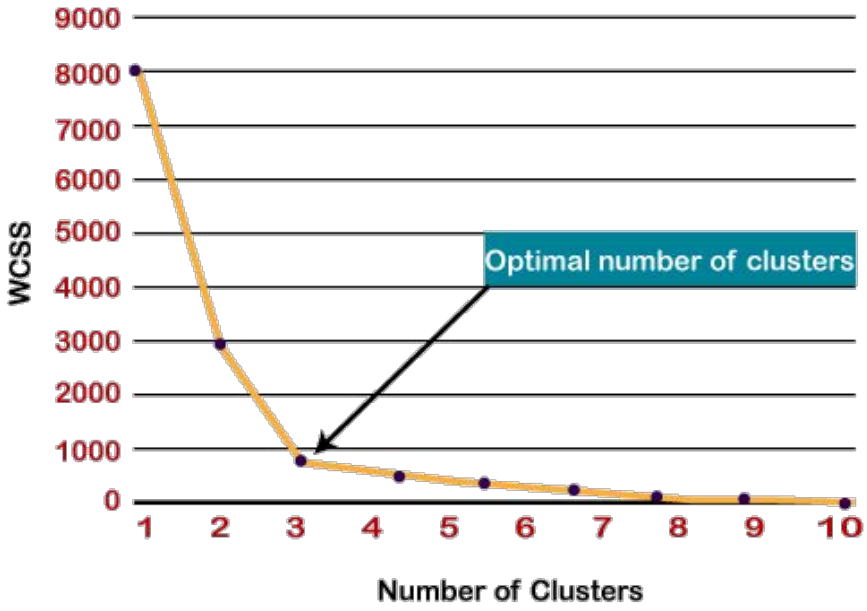

https://www.javatpoint.com/k-means-clustering-algorithm-in-machine-learning

Silhouette Score

- So sánh mức độ gần gũi giữa các điểm trong cụm với các điểm ở cụm khác.

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

  - a(i): Khoảng cách trung bình từ điểm i đến các điểm trong cùng cụm.
  - b(i): Khoảng cách trung bình từ điểm i đến các điểm trong cụm gần nhất.

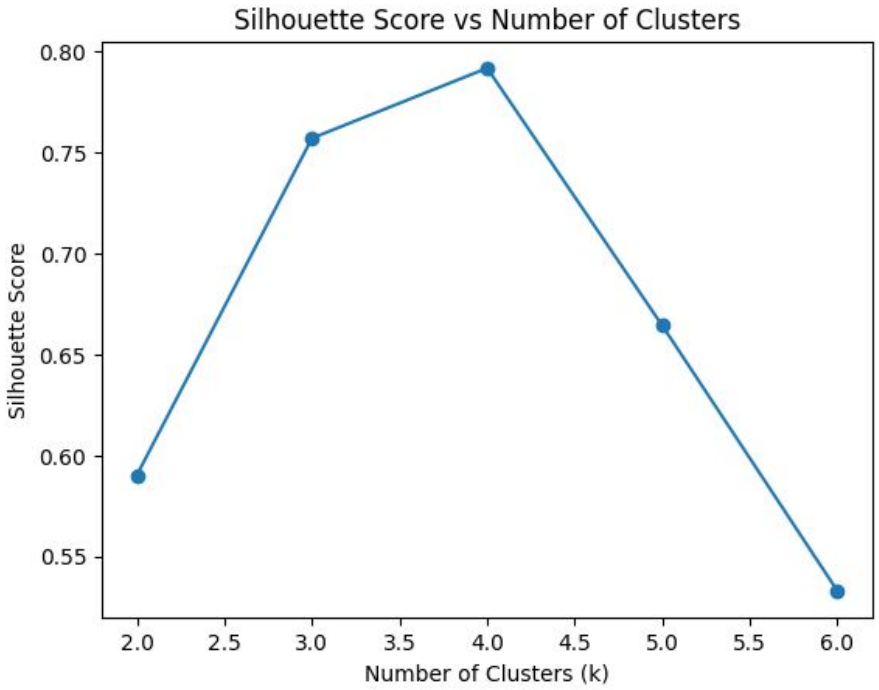

Gap Statistic

- So sánh hiệu quả phân cụm trên dữ liệu thực với dữ liệu ngẫu nhiên (không có cấu trúc).

$$\mathrm{Gap}(k) = \mathbb{E}[\log(W_k^{\mathrm{random}})] - \log(W_k^{\mathrm{data}})$$

- W_k^{random}: WCSS trên random data.
- W_k^{data}: WCSS trên actual data.

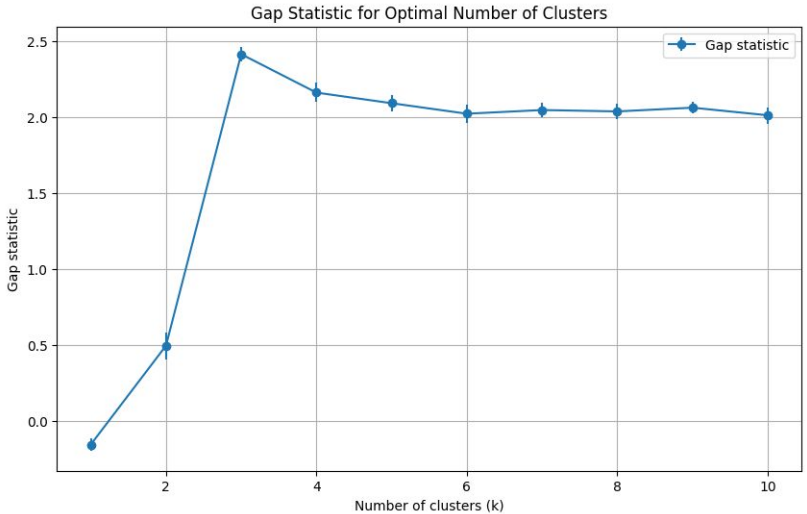

DBSCAN

Clustering Algorithms

Introduction

- DBSCAN là một thuật toán phân cụm dựa trên mật độ, được thiết kế để tìm các cụm dữ liệu có hình dạng bất kỳ và phát hiện các điểm nhiễu (noise).
- Không yêu cầu biết trước số cụm.

Mục tiêu:

- Nhóm các điểm dữ liệu gần nhau vào cùng một cụm.
- Phát hiện và loại bỏ các điểm dữ liệu không thuộc cụm nào (outliers).

Terms

1. **Epsilon (ε)**: Bán kính để xác định khu vực lân cận của một điểm.
2. **MinPts**: Số lượng điểm tối thiểu cần thiết để một khu vực được coi là đủ mật độ.
3. **Loại điểm trong DBSCAN**:
   - **Core Point**: Điểm có ít nhất MinPts điểm khác nằm trong khoảng ε.
   - **Border Point**: Điểm không phải là Core Point nhưng nằm trong vùng lân cận của một Core Point.
   - **Noise**: Điểm không thuộc Core Point hoặc Border Point.

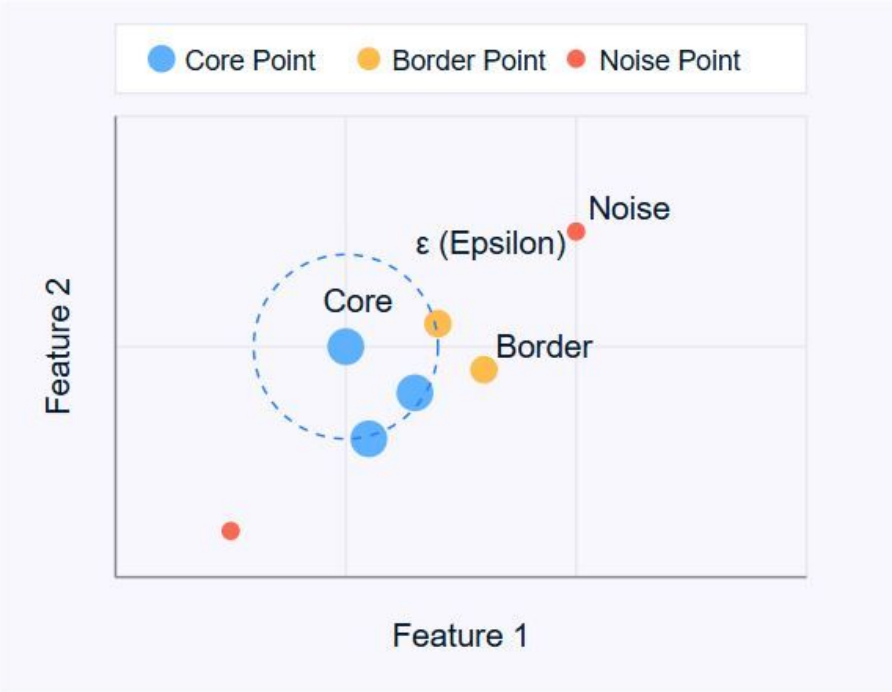

Source: *datacamp*

DBSCAN Algorithm

Bước 1: Chọn một điểm dữ liệu chưa được xử lý.

Bước 2: Nếu điểm đó có ít nhất **MinPts** điểm lân cận trong khoảng **ε**, nó được đánh dấu là **CorePoint** và cụm được tạo.

Bước 3: Lặp lại với tất cả các điểm trong cụm.

Bước 4: Nếu một điểm không thuộc cụm nào và không đủ điều kiện là **CorePoint**, nó được đánh dấu là **Noise**.

Bước 5: Kết thúc khi tất cả các điểm được xử lý.

Applications

1. Phân tích dữ liệu địa lý (GIS).
2. Phát hiện bất thường trong bảo mật.
3. Phân nhóm các mẫu sinh học hoặc di truyền.

An Example

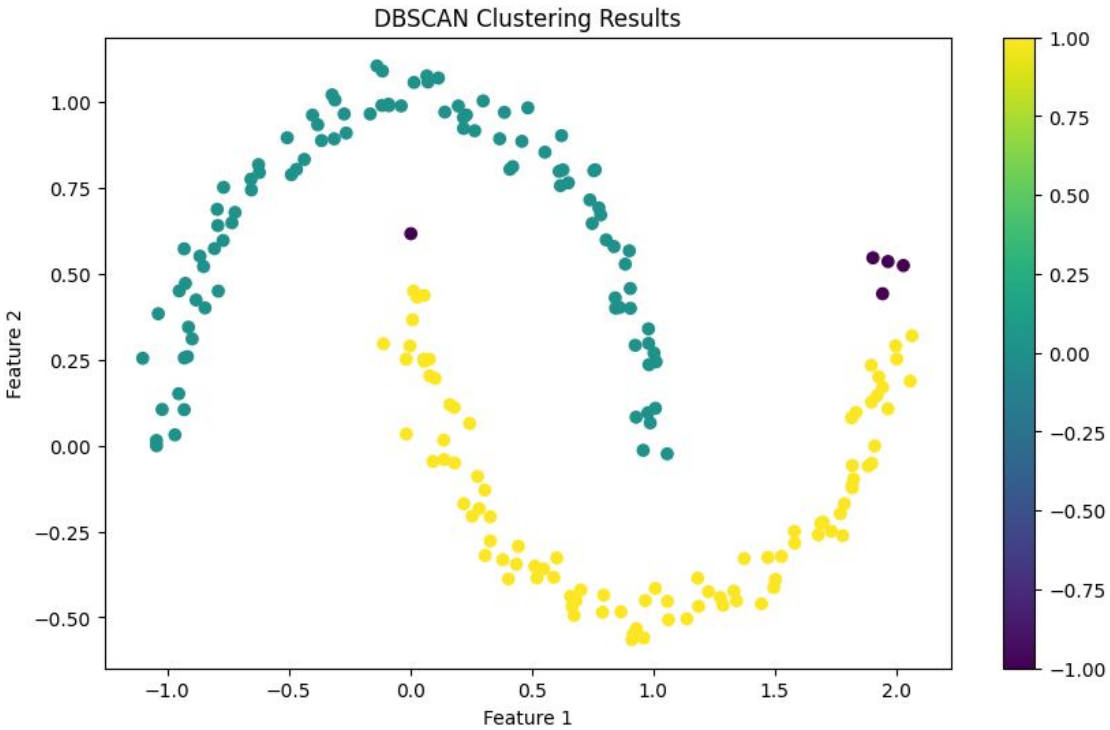
DBSCAN Clustering Results
Feature 2
Feature 1
1.00
0.75
0.50
0.25
0.00
−0.25
−0.50
−1.0
−0.5
0.0
0.5
1.0
1.5
2.0
1.00
0.75
0.50
0.25
0.00
−0.25
−0.50
−0.75
−1.00

Selecting ε and MinPts

Phương pháp Elbow cho ε:

- Sắp xếp các khoảng cách lân cận theo thứ tự tăng dần.
- Chọn điểm gãy (elbow) làm giá trị ε.

Dựa trên kinh nghiệm cho MinPts:

- MinPts ≥ 2 × số chiều dữ liệu.

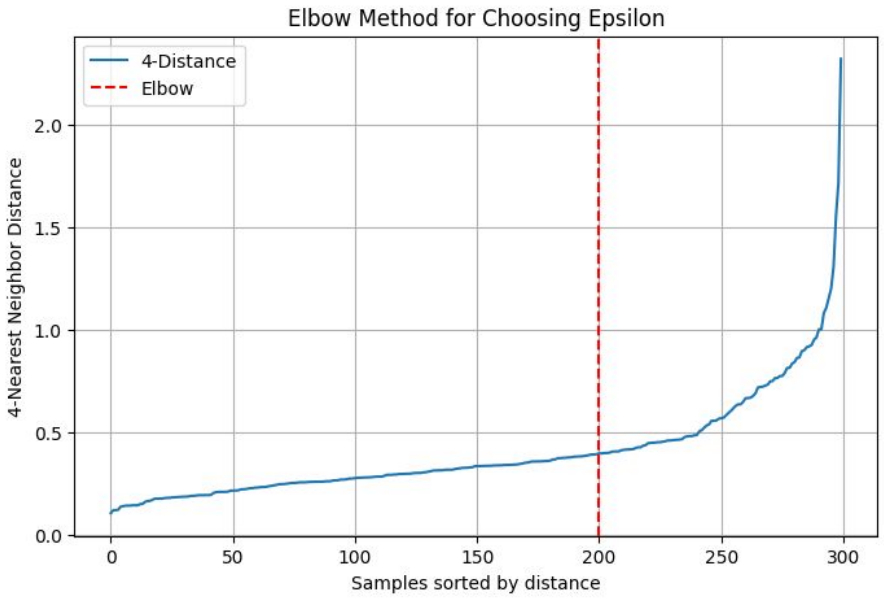

Agglomerative Clustering

Clustering Algorithms

Introduction

Định nghĩa:
Hierarchical Clustering là một thuật toán phân cụm sắp xếp dữ liệu thành một cây phân cấp (dendrogram), cung cấp khả năng quan sát mối quan hệ giữa các cụm.

Mục tiêu:

- Phân nhóm dữ liệu thành các cụm với nhiều cấp độ.
- Tìm hiểu cấu trúc phân cấp trong dữ liệu.

Types of Hierarchical Clustering

Agglomerative Clustering (Hợp nhất):

- Bắt đầu với mỗi điểm dữ liệu là một cụm riêng lẻ.
- Liên tục hợp nhất các cụm gần nhất cho đến khi tất cả dữ liệu được gom vào một cụm lớn.

Divisive Clustering (Phân chia):

- Bắt đầu với một cụm chứa tất cả dữ liệu.
- Liên tục phân chia cụm thành các cụm nhỏ hơn.

Agglomerative Clustering

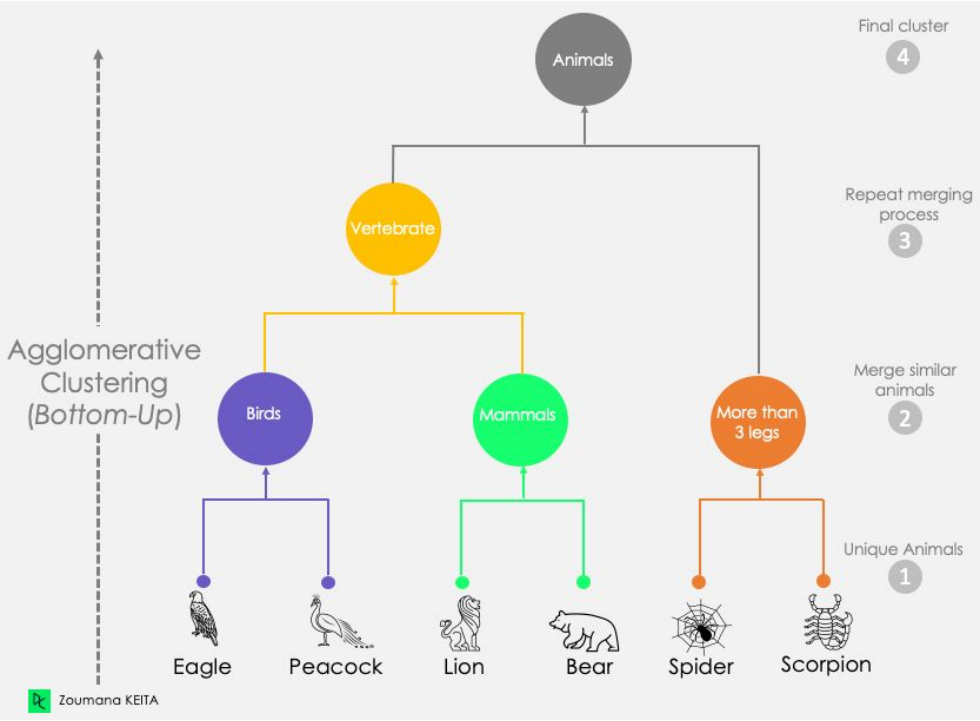

Divisive Clustering

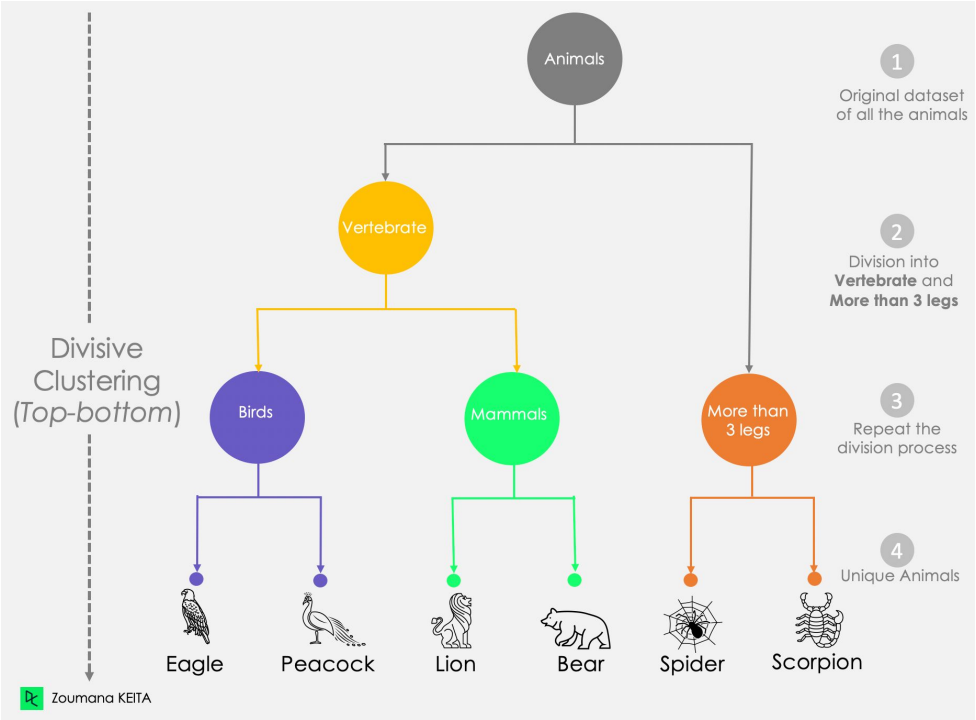

Applications

- Phân loại văn bản hoặc hình ảnh.
- Phân tích gen sinh học.
- Tổ chức thông tin phân cấp.

Single linkage

- 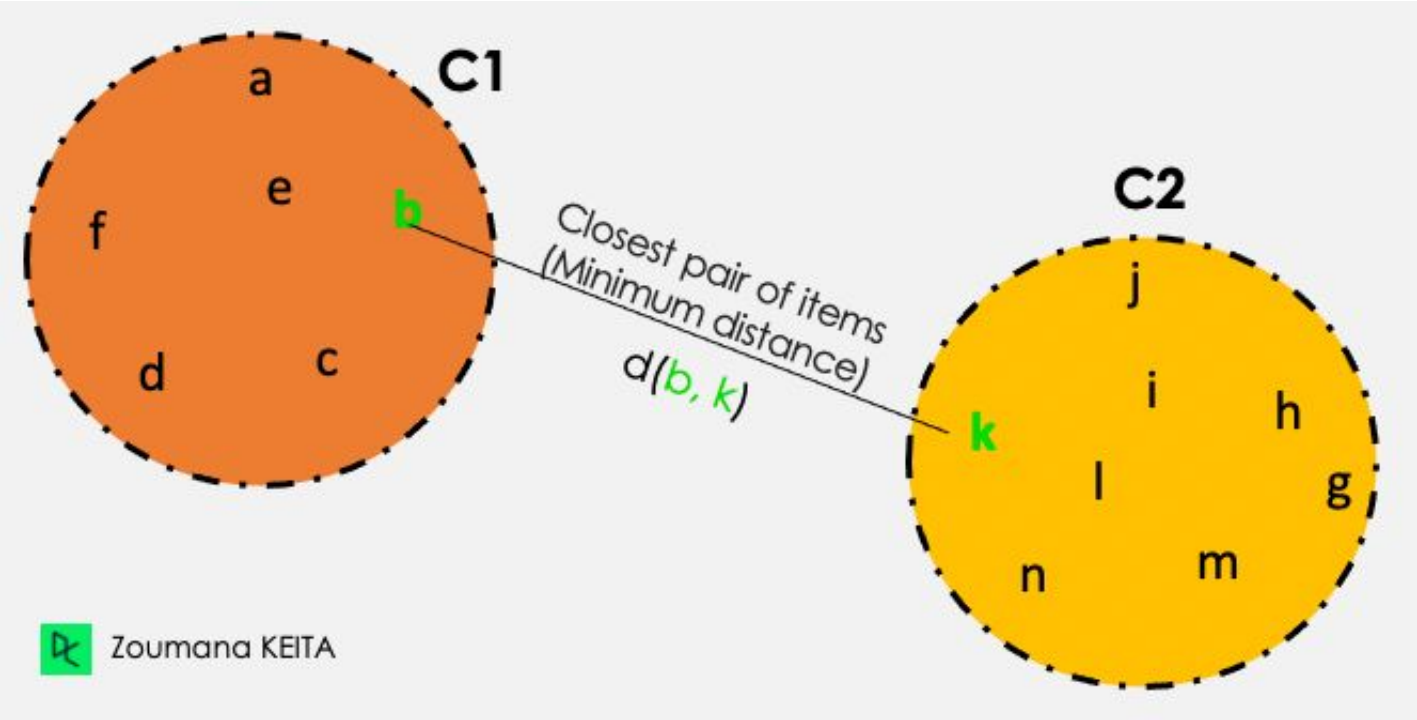

Complete linkage

- 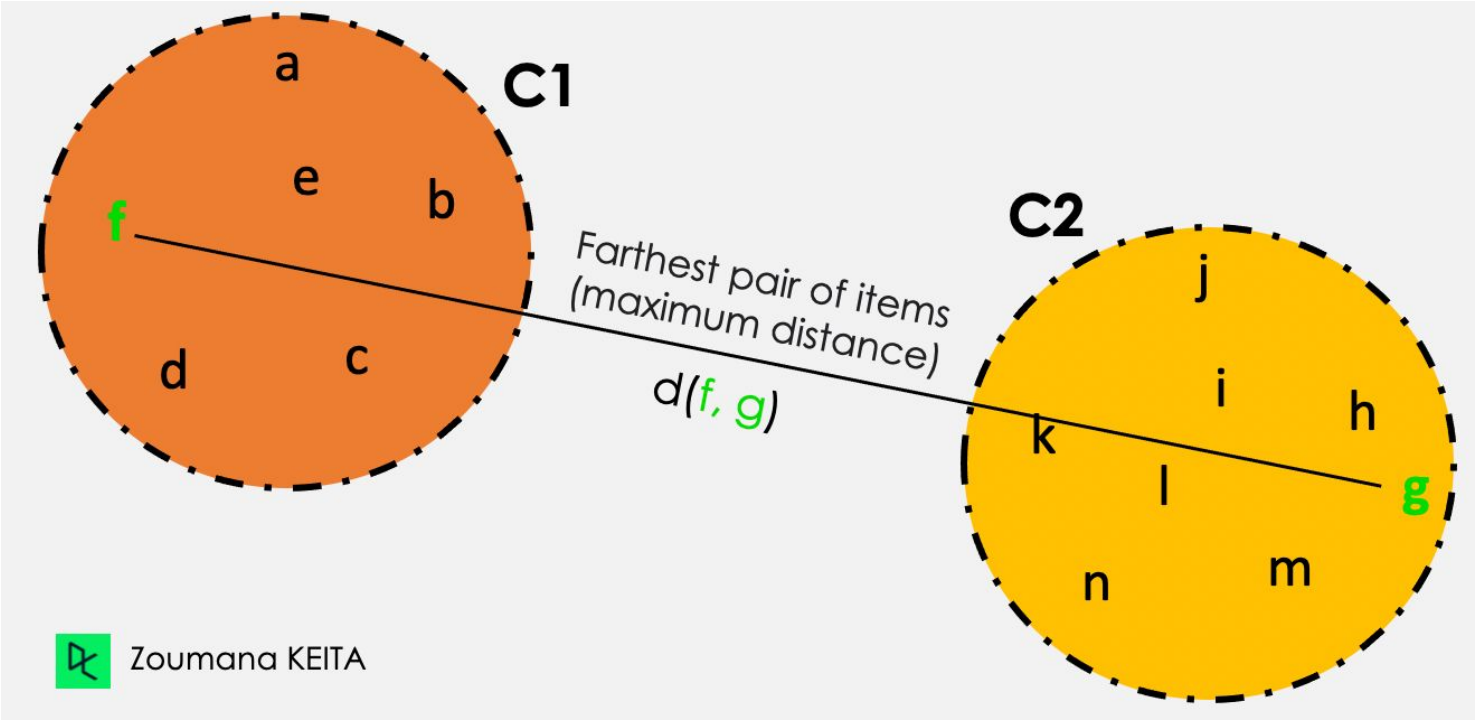

Average linkage

- 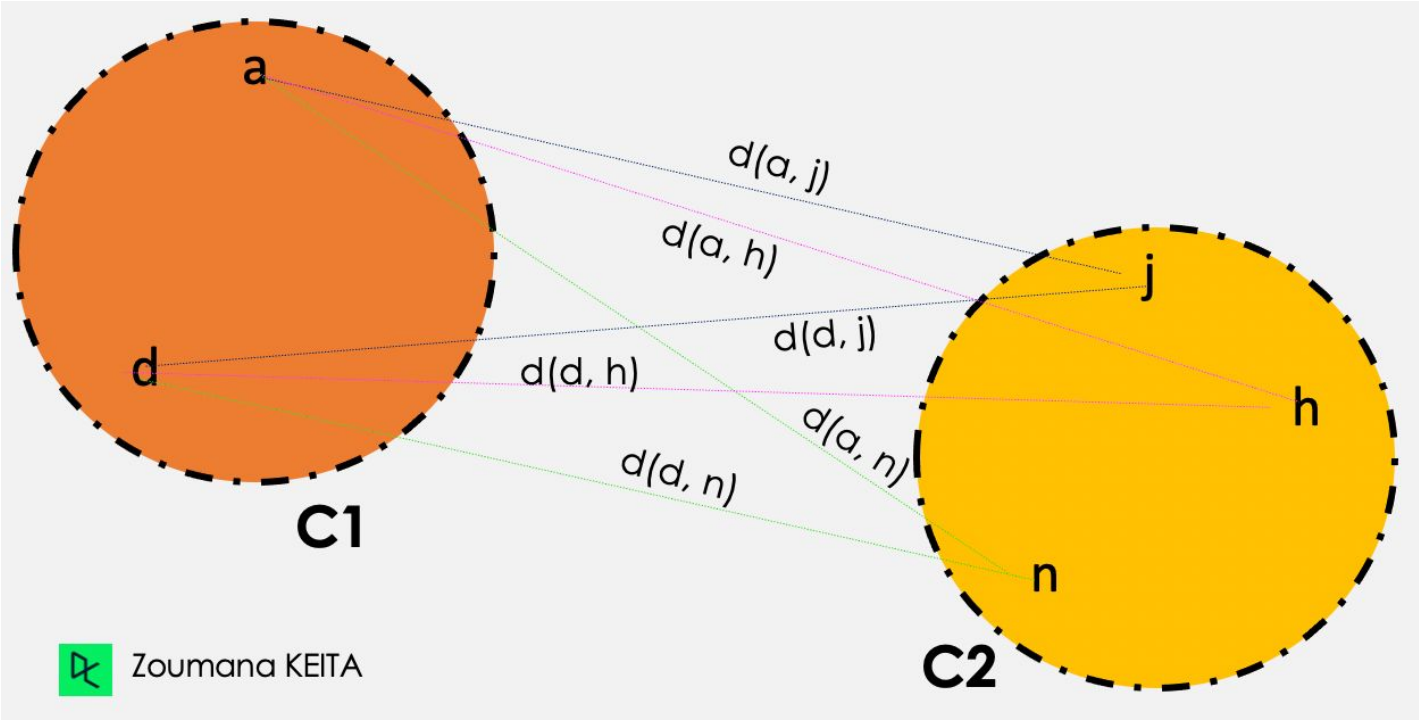

Hierarchical Clustering Process

Tính khoảng cách giữa các điểm dữ liệu:

- Sử dụng các phép đo khoảng cách như Euclidean, Manhattan.

Liên kết cụm (Linkage):

- **Single linkage**: Khoảng cách giữa hai điểm gần nhất.
- **Complete linkage**: Khoảng cách giữa hai điểm xa nhất.
- **Average linkage**: Trung bình khoảng cách giữa tất cả các điểm.

Xây dựng dendrogram:

- Một sơ đồ dạng cây biểu diễn quá trình hợp nhất hoặc phân chia cụm.

An example - Complete linkage

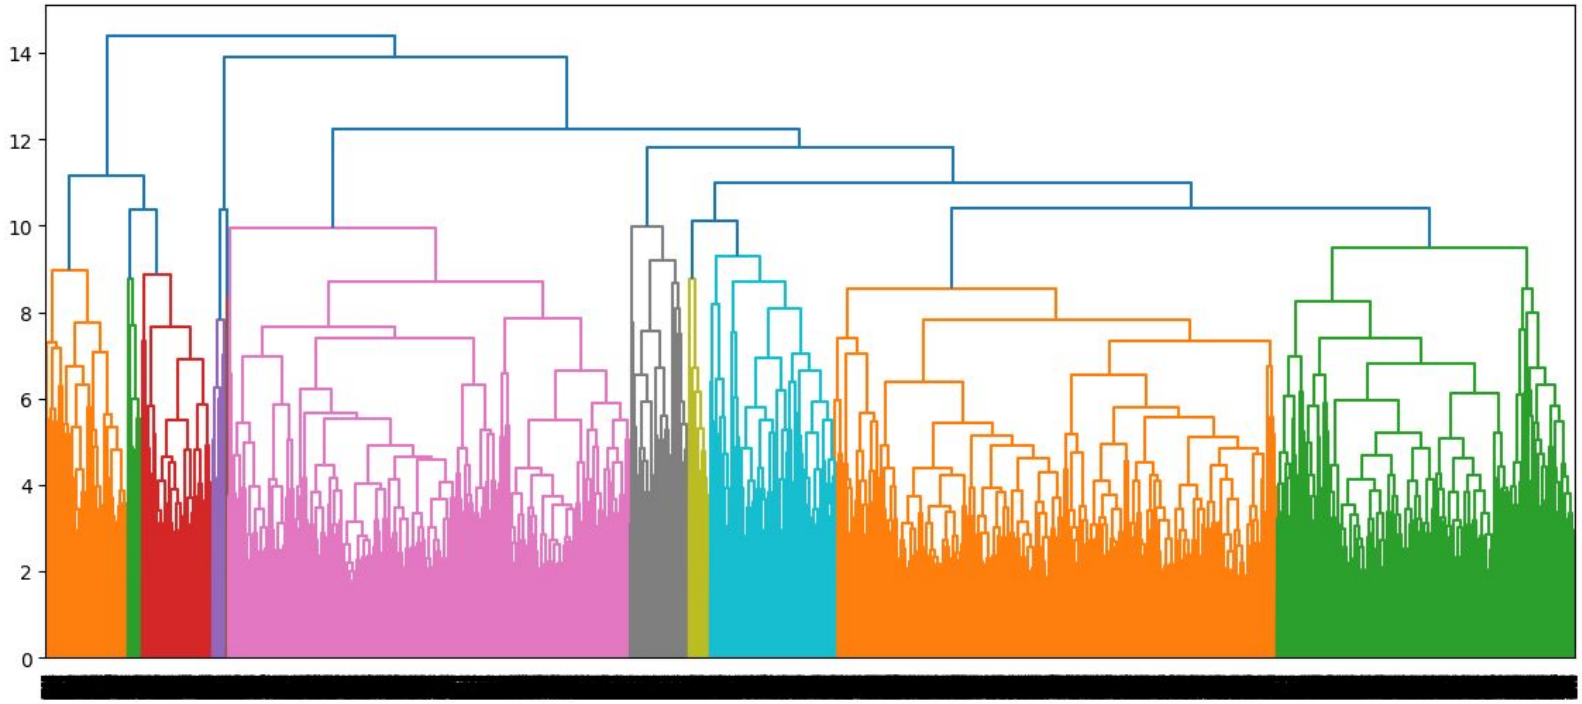

An example - Average linkage

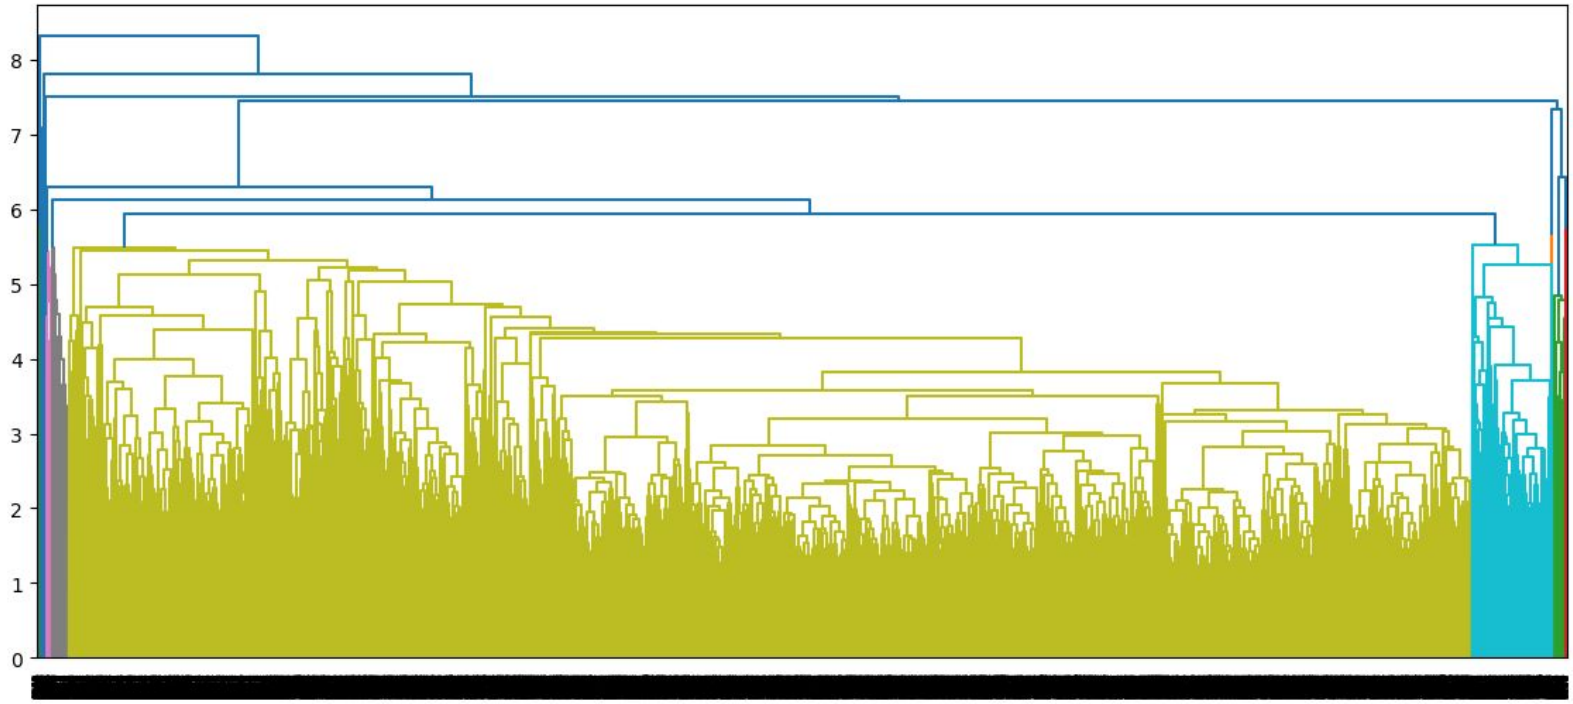

An example - Single linkage

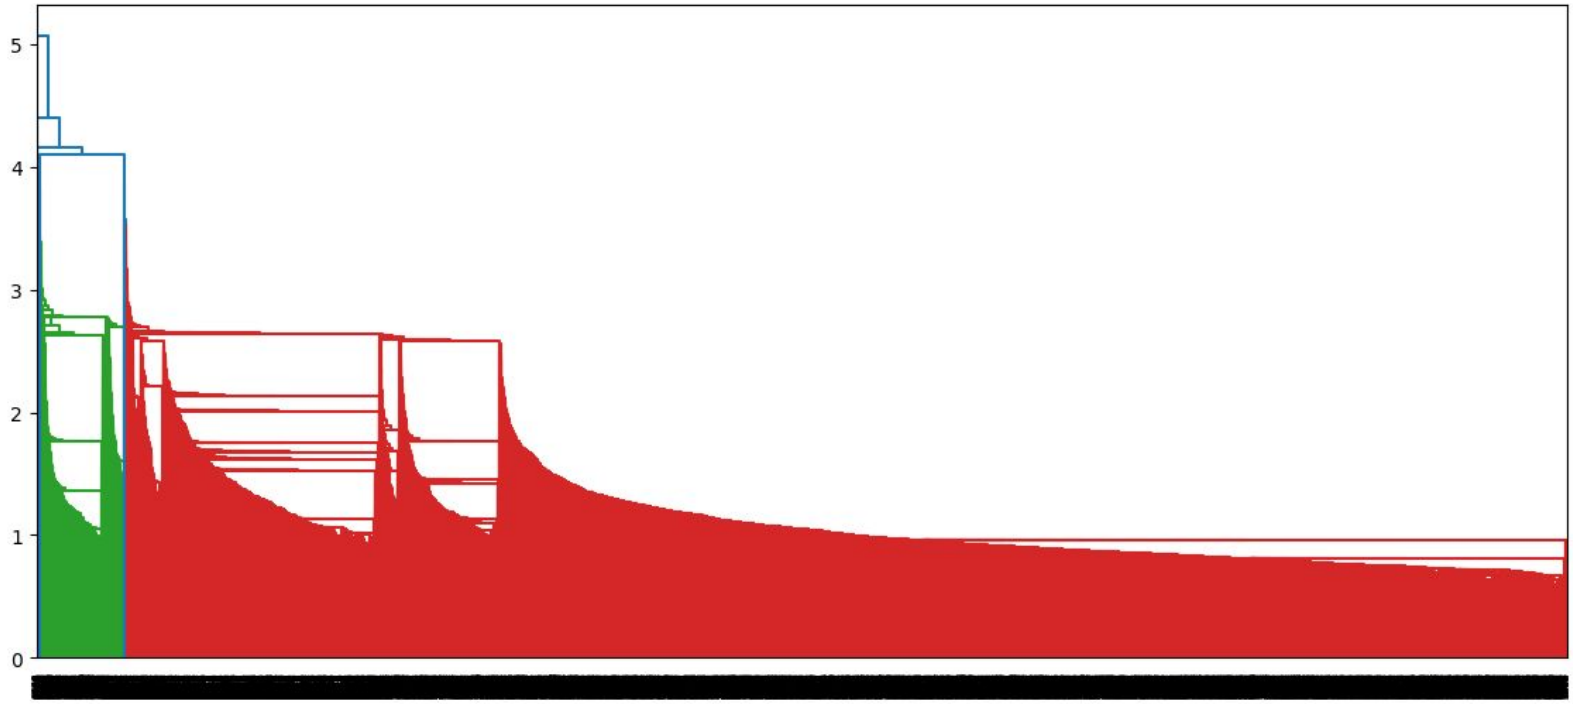

Comparison with Other Clustering Algorithms

K-means:

- Cần xác định số cụm trước.
- Phân cụm tốt hơn khi dữ liệu có hình dạng hình cầu.

DBSCAN:

- Tìm các cụm mật độ cao.
- Xử lý tốt dữ liệu nhiễu và các cụm không đồng nhất.

Hierarchical Clustering:

- Không cần số cụm trước.
- Tập trung vào cấu trúc phân cấp.

References

[1] https://cloud.google.com/discover/what-is-unsupervised-learning?hl=en

[2] https://wandb.ai/mostafaibrahim17/ml-articles/reports/An-Introduction-to-Unsupervised-Learning--VmlldzozMjYzNzcw

[3] https://youtu.be/oQ1gk7aukxg

[4] https://www.rocketsource.com/blog/machine-learning-models/